



Dialoguer avec des scientifiques du passé : conception d'un agent conversationnel multimodal animé par l'IA

Elham Abbassi

Master en systèmes et services numériques - orientation de transformation
numérique – Université de Genève

Prof. Giovanna Di Marzo Serugendo
Prof. Lamai Fariha

25 juin 2025

Table des matières

1	Introduction	2
1.1	Contexte du projet	2
1.2	Défis soulevés par le projet	4
2	Projets similaires et limites des approches actuelles	4
3	Analyse comparative des technologies par usage	6
3.1	Clonage de voix	6
3.2	Synchronisation labiale et animation faciale	12
3.3	Exploration de la piste 3D	16
3.4	Traitement du langage naturel (NLP) pour la conversation	19
3.5	Génération de Vidéo à partir d'une Photo, d'une Voix et d'un Texte	21
4	Méthodologie et mise en œuvre	23
4.1	Objectifs fonctionnels et techniques	23
4.2	Architecture du système	24
4.3	Méthodologie de développement	28
4.4	Implémentation par modal	29
4.4.1	Organisation du code et modules utilisés	29
4.4.2	Processus d'implémentation détaillé	30
4.5	Prototype de l'application	36
4.6	Tests, évaluations et retours	43
5	Discussion et perspectives	45
5.1	Réponses aux questions de recherche	45
5.2	Limites de la solution actuelle	46
5.3	Perspectives d'amélioration	47
6	Conclusion	49

1 Introduction

L'intelligence artificielle (IA) évolue rapidement et transforme de nombreux domaines autour de nous. Elle est présente dans la médecine, où elle contribue à améliorer les diagnostics et le suivi des patients, dans la culture à travers la création automatisée de textes, d'images ou de musique, mais aussi dans l'éducation en proposant des parcours d'apprentissage personnalisés. Dans l'industrie, elle permet d'optimiser les processus de production, de détecter les anomalies et d'automatiser certaines tâches. Nous assistons ainsi à une intégration progressive de l'IA dans notre quotidien, rendant les échanges entre humains et machines toujours plus fluides et efficaces.

Parallèlement, les modèles spécialisés en traitement du langage naturel (NLP), en synthèse vocale, en vision par ordinateur ou encore en animation automatique progressent de manière significative. Grâce à eux, il devient possible de créer des expériences interactives riches, immersives et multimodales. Nous interagissons désormais avec des assistants vocaux, discutons avec des agents conversationnels, écoutons des voix de synthèse très réalistes et voyons des visages animés par l'IA capables de parler et de simuler des expressions humaines.

L'évolution des technologies d'intelligence artificielle, en particulier dans les domaines du langage, de la voix et de l'image, a profondément modifié notre manière d'interagir avec les systèmes numériques. Il est désormais possible de générer automatiquement des textes cohérents, de produire des voix synthétiques naturelles, et même de donner vie à une simple photo par le biais de l'animation vidéo. Ces avancées ouvrent la voie à de nouveaux usages dans de nombreux domaines comme agents pédagogiques, guides interactifs, simulateurs de conversation, avatars destinés à la santé mentale ou à la vulgarisation scientifique.

1.1 Contexte du projet

Dans ce contexte, nous avons reçu une commande dans le cadre d'un projet de recherche universitaire pour créer un hologramme interactif de **Jean Piaget**, célèbre psychologue du développement de l'enfant.

L'objectif était de permettre à des utilisateurs d'interagir directement avec un avatar animé de Piaget, capable de répondre oralement à des questions sur sa vie, ses travaux et ses théories, dans une expérience éducative vivante et intuitive.

Les dispositifs holographiques que l'on retrouve dans certains musées ou événements culturels reposent sur des infrastructures matérielles et logicielles particulièrement sophistiquées. Leur fonctionnement implique souvent l'utilisation de modèles 3D ou vidéos haute résolution, de systèmes de capture volumétrique, ainsi que de projecteurs spécifiques capables de créer une illusion de volume dans l'espace (voir Vers une incarnation holographique complète).

Animer un tel modèle nécessite en outre des calculs complexes pour garantir la cohérence des mouvements, des expressions faciales et de la synchronisation labiale avec un contenu audio. Ce type d'installation requiert non seulement un matériel spécialisé, mais également une chaîne de production numérique maîtrisée, allant de la reconstruction 3D d'une personne à l'animation fluide du modèle dans un environnement simulé, ou créer une vidéo de bonne qualité montrant différents corps humains

en mouvement, avec une animation fluide et naturelle, sans effet robotique

Face à cette complexité, ce projet a volontairement écarté l’usage de dispositifs holographiques physiques, afin de proposer une solution plus accessible, légère et facilement reproductible. Le système repose uniquement sur des éléments simples, une photographie de la personne, un extrait vocal, et des outils d’intelligence artificielle permettant de générer une animation faciale synchronisée et simuler une interaction crédible avec un personnage animé, tout en s’affranchissant des contraintes techniques, logistiques et matérielles liées aux solutions holographiques classiques. Elle facilite ainsi un déploiement plus large dans des contextes éducatifs, scientifiques ou personnels.

Cette réflexion a guidé notre démarche, pour une approche 2D plus accessible pour donner vie à des esprits historiques incarnées avec leurs connaissances. Notre solution propose une alternative vivante pour poser des questions comme dans une conversation naturelle, et recevoir des réponses animées, vocales et incarnées, fidèles à leur personnalité. Cette démarche s’appuie sur ces piliers technologiques :

- **Visuelle** : animation d’un visage à partir d’une simple photo, avec synchronisation labiale et mouvements naturels.
- **Vocale** : génération de réponses parlées, à l’aide d’un modèle NLP et d’une voix clonée aussi fidèle que possible à celle du personnage.
- **Personnalisée** : formulation des réponses en cohérence avec le style, les idées et les connaissances du personnage incarné, pour donner l’illusion qu’il s’adresse lui-même à l’utilisateur.
- **Documentaire** : appui des réponses sur des sources fiables, grâce à l’intégration d’un système de RAG (Retrieval-Augmented Generation).

Nous avons ainsi développé une application web interactive, permettant à l’utilisateur de dialoguer avec des figures scientifiques, sous forme de vidéos animées générées à partir d’une photo de la personne avec laquelle l’utilisateur souhaite interagir. L’expérience permet d’entendre leurs réponses dans leur propre voix, de voir leurs visages s’animer, et d’approfondir leurs idées à travers une conversation personnalisée.

Cette démarche vise à renouveler les modes de transmission du savoir scientifique, en rendant les connaissances plus accessibles, vivantes, engageantes. Elle s’inscrit dans un mouvement plus large de transformation des outils éducatifs par l’IA, et interroge en même temps les dimensions éthiques et culturelles de la reconstitution numérique de personnalités disparues.

C’est dans cette dynamique que notre projet prend place. Ce que nous avons voulu explorer, ce n’est pas simplement un chatbot ou un assistant vocal, mais une forme d’échange plus incarnée, plus vivante, faire parler un figure scientifique historique, comme s’il était là devant nous. Pour cela, nous avons combiné plusieurs composants technologiques comme génération de texte, synthèse vocale, animation d’images, reconnaissance vocale, clonage de voix, génération d’avatar, extraction de contenu documentaire (PDF ou site web), génération vidéo synchronisée à l’audio, et synchronisation labiale. L’objectif étant de rendre le savoir scientifique plus engageant et accessible à tous.

1.2 Défis soulevés par le projet

Les outils actuels d'intelligence artificielle permettent de générer du texte cohérent, de synthétiser une voix réaliste et de produire des animations faciales à partir d'une simple image. Ces avancées sont prometteuses, mais dans le cadre de notre projet, nous avons rapidement constaté l'absence d'une solution unifiée, libre ou semi-libre, qui permette de recréer une expérience d'interaction fluide, personnalisable avec une personnalité scientifique recréée numériquement.

Nous avons donc voulu évaluer les outils disponibles, identifier leurs limites, et concevoir un prototype qui réponde à ce besoin spécifique. Cette démarche nous a conduits à formuler les interrogations suivantes :

- **Recréation de la personnalité d'un scientifique** : peut-on simuler sa voix, son apparence et ses idées à travers des technologies d'IA, tout en conservant une fidélité stylistique et intellectuelle ?
- **Animation faciale et vocale à partir d'une simple photo** : est-il possible de générer un avatar animé, avec une synchronisation réaliste des mouvements du visage et de la tête, sans recourir à un modèle 3D complexe ?
- **Interface interactive tout-en-un** : peut-on regrouper synthèse vocale, animation visuelle, génération de texte et compréhension du langage naturel dans un système accessible, sans dépendre de solutions propriétaires coûteuses ?
- **Fiabilité des réponses générées** : comment s'assurer que l'IA s'exprime en cohérence avec les écrits et la pensée de la figure scientifique ? Peut-on utiliser efficacement le RAG (Retrieval-Augmented Generation) pour ancrer les réponses dans des sources vérifiables ?
- **Fidélité visuelle de l'avatar** : jusqu'à quel point peut-on préserver les traits distinctifs d'un personnage à partir d'une simple image, malgré les contraintes techniques liées à la qualité d'entrée ou aux outils d'animation disponibles ?
- **Immersion sans 3D** : dans quelle mesure peut-on créer une expérience réaliste et engageante, à défaut d'un hologramme complet, en combinant des techniques d'animation, de génération audio et de NLP dans une interface interactive ?

2 Projets similaires et limites des approches actuelles

Ces dernières années, plusieurs projets ont tenté de repousser les frontières de l'intelligence artificielle en proposant des interactions plus réalistes avec des entités virtuelles. Certains d'entre eux se sont approchés de notre objectif, mais aucun ne répond pleinement aux exigences d'une interaction cohérente, orale et personnalisée avec un figure scientifique historique.

Parmi les initiatives marquantes, on trouve par exemple des projets de chatbots incarnés avec des avatars animés capables de tenir une conversation. C'est le cas de Replika [1], Soul Machines [2] ou encore de démonstrations basées sur MetaHuman Creator d'Epic Games [3], qui visent à créer des interlocuteurs virtuels crédibles, souvent à visée commerciale, éducative ou thérapeutique. Toutefois, ces systèmes reposent sur des personnages fictifs, et non sur des figures historiques authentiques.

D’autres projets, comme celui développés autour de figures célèbres Einstein [4], ont utilisé des technologies de synthèse vocale ou d’animation faciale pour leur redonner une forme de présence. Des plateformes comme D-ID [5] ou MyHeritage Deep Nostalgia [6] permettent par exemple d’animer une photo à partir d’un texte ou d’un fichier audio. Cependant, l’interaction n’est pas dynamique et se limite à une vidéo prédéfinie.

En parallèle, certaines entreprises ont exploré le clonage vocal réaliste, comme ElevenLabs [7], Resemble AI [8], ou iSpeech [9], avec des résultats impressionnants pour les langues bien représentées. Toutefois, ces outils sont rarement gratuits. Dans le cadre de notre projet de recherche, nous avons d’abord cherché à identifier et tester des solutions open source ou accessibles gratuitement, avant d’envisager l’intégration de services commerciaux.

Et pour finir, il existe également des projets holographiques similaires, qui cherchent à recréer la présence de figures, par exemple des chercheurs du MIT ont récemment développé une approche nommée *tensor holography*, qui utilise le deep learning pour générer quasi instantanément des hologrammes 3D à partir d’images, même sur des appareils mobiles [10]. Parallèlement, la communauté open source explore aussi des alternatives plus accessibles. Des discussions telles que celle présente sur Debian-fr abordent la possibilité de simuler des effets holographiques via des outils libres combinant synthèse vocale et rendu animé 2D [11]. Cependant, ces solutions restent encore expérimentales et ne permettent pas une interaction vocale incarnée et fluide avec un personnage.

Face à ces initiatives, nous relevons plusieurs limites qui ont motivé la conception de notre propre solution :

- **Absence de véritable mode « chat » fluide** : la plupart des plateformes se contentent de générer une vidéo à partir d’un texte pré-saisi, il n’existe pas de boucle question-réponse en temps quasi-réel avec un agent incarné.
- **Pas de connexion native à un LLM** : les réponses sont scénarisées ou statiques, aucune intégration directe avec un grand modèle de langage pour produire des réponses dynamiques.
- **Restrictions sur les photos de personnalités réelles** : certaines solutions (ex. D-ID, Vidnoz) interdisent l’utilisation d’images de figures historiques ou célèbres pour des raisons légales, limitant les cas d’usage.
- **Manque de personnalisation ouverte** : les outils commerciaux offrent peu de contrôle sur le style, la langue ou le ton du personnage, et ne permettent pas d’injecter un prompt personnalisé.
- **Peu ou pas d’ancrage documentaire** : aucune n’exploite un mécanisme type RAG pour s’appuyer sur des sources académiques, ce qui limite la fiabilité pédagogique.

C’est à partir de ce constat que notre projet est né qui propose une solution cohérente et intégrée, qui combine les apports de la synthèse vocale, de l’animation faciale, du traitement du langage naturel, et de l’accès à une base documentaire fiable. Une expérience multimodale, réaliste et accessible, au service de la transmission du savoir.

3 Analyse comparative des technologies par usage

Au démarrage du projet, le chemin n'était pas encore balisé et nous avons exploré plusieurs pistes afin d'identifier la plus adaptée. Cette diversité de méthodes d'évaluation reflète une démarche exploratoire, visant à sélectionner les briques technologiques les plus adaptées pour atteindre les objectifs du projet.

Dans cette section, nous présentons les outils technologiques explorés dans les différents modales nécessaires à la réalisation de notre application notamment synthèse vocale, animation d'image, création d'avatar, interface de chat, et génération de vidéo.

Chaque modale technologique joue un rôle fondamental dans notre système, et leur combinaison est indispensable pour parvenir à une interaction cohérente, fluide et multimodale avec un personnage animé.

Cette approche itérative nous a permis de mieux comprendre les contraintes liées à l'implémentation, d'affiner nos choix technologiques, et de sélectionner les combinaisons les plus robustes pour obtenir un résultat fonctionnel et convaincant.

Ainsi, chaque outil présenté dans cette analyse comparative a été sélectionné ou écarté en fonction de critères concrets liés à notre projet comme la qualité de rendu, la simplicité d'usage, l'accessibilité, le niveau de personnalisation, le coût et la compatibilité avec les autres composants.

Il est important de noter que tous les outils listés n'ont pas été intégrés directement dans l'application. Certains ont été testés à travers une documentation technique, des articles ou des démonstrations en ligne, tandis que d'autres ont fait l'objet d'expérimentations concrètes via du code.

3.1 Clonage de voix

Dans le cadre de ce projet, la voix joue un rôle central dans la perception de la présence du personnage virtuel. Il ne s'agissait pas seulement de faire parler un assistant générique, mais de donner à la figure représentée, une identité sonore cohérente, reconnaissable et crédible. La voix constitue un vecteur essentiel d'émotion, de style et de réalisme dans l'interaction. Elle participe directement à la sensation de dialoguer avec une personne et pas avec une machine.

Le clonage vocal permet de générer une voix de synthèse personnalisée à partir d'un court enregistrement audio, en reproduisant les caractéristiques prosodiques et les intonations de la voix d'origine. Cette technologie s'est révélée particulièrement utile dans notre projet.

Cette étape était indispensable pour renforcer l'illusion d'une interaction authentique. Une voix impersonnelle ou mal adaptée aurait nui à la crédibilité de l'expérience. À l'inverse, une voix synthétique proche de l'original donne une sensation plus réaliste. Ce choix technologique s'est donc inscrit dans une volonté de restituer au plus près l'identité vocale du personnage historique, tout en respectant les contraintes techniques du projet.

Outils testés pour clonage :

1. PlayHT [12]

PlayHT est une plateforme en ligne de synthèse vocale qui propose un large éventail de voix préenregistrées, ainsi que des options de clonage vocal. Son interface intuitive permet aux utilisateurs de générer rapidement des fichiers audios à partir de texte, en sélectionnant la langue, le style ou le ton souhaité.

Nous avons testé cet outil car il propose une option permettant de choisir différents tons et styles de voix. Cette fonctionnalité nous a permis d'expérimenter plusieurs variantes pour trouver celle qui se rapproche le plus du timbre réel et de la manière de parler de la personne cible.

Résultat : La qualité de synthèse en anglais est globalement bonne, mais en français, la prononciation est souvent imprécise et le rendu manque d'authenticité. L'outil se montre limité dès lors qu'il s'agit de personnaliser finement la voix clonée.

Points positifs :

- Interface claire et facile à utiliser
- Plusieurs voix et styles disponibles en anglais
- Génération rapide de fichiers audio

Points négatifs :

- Qualité médiocre en français (prononciation, intonation)
- Peu d'options de personnalisation vocale
- Accès limité dans la version gratuite
- Pas d'option pour intégrer directement l'outil dans notre application via une API ou un SDK

2. ElevenLabs [7]

ElevenLabs est un service de clonage vocal avancé, largement reconnu pour la qualité et le réalisme de ses voix synthétiques. Il s'adresse à des usages professionnels comme les livres audio, les assistants vocaux ou encore la localisation de contenu multilingue.

Dans le cadre de notre projet, ElevenLabs a été utilisé pour générer une voix fidèle à celle d'une personne réelle. L'objectif était d'obtenir une voix personnalisée, claire, et suffisamment expressive pour simuler une interaction naturelle.

Résultat : Les performances ont été nettement supérieures à celles des autres outils testés. La voix générée était fluide, avec une bonne prononciation en français et une expressivité crédible (pause, ton, rythme). Le clonage vocal a fonctionné avec un court extrait audio, sans entraînement complexe.

Points positifs :

- Qualité vocale très élevée, proche d'une voix humaine réelle
- Support du français avec une bonne prosodie
- Fonctionne avec peu de données pour cloner une voix
- Documentation complète et possibilité d'intégration dans notre projet via une API key.

Points négatifs :

- Version gratuite limitée et aucune option de clonage.

3. Real-Time Voice Cloning (RTVC) [13]

RTVC est un projet open source conçu pour cloner une voix à partir de quelques secondes d’audio, reposant sur une architecture en trois volets :

- **Encoder** : extrait l’empreinte vocale (*speaker embedding*) de l’enregistrement source, c’est-à-dire les caractéristiques uniques du timbre et de la prosodie du locuteur.
- **Synthesizer** : combine cet embedding avec un texte d’entrée pour générer un spectrogramme de sortie (représentation temps-fréquence de la parole).
- **Vocoder** : convertit le spectrogramme en onde audio lisible, produisant ainsi la voix clonée.

Projet libre offrant un clonage vocal rapide à partir d’un court extrait audio, sans dépendre d’une API externe.

Résultat : Nous n’avons pas pu exécuter directement le code de RTVC dans notre environnement local, car l’installation nécessite de nombreuses dépendances Python (PyTorch, CUDA, packages audio...) et notre configuration matérielle était limitée. Cependant, nous avons identifié la possibilité de tester le projet via une interface graphique en local avec Anaconda. Cela nous a permis d’examiner des exemples de résultats, notamment en français, et de constater que la qualité reste faible, avec un rendu robotique et peu intelligible.

Points positifs :

- Clonage rapide avec peu de données d’entraînement.
- Code libre et entièrement modifiable.
- Exécution possible en local, sans appel API payant.

Points négatifs :

- Qualité synthétique, manque de naturel (effet robotique), surtout en français.
- Dépendances nombreuses et configuration technique complexe.
- Absence d’interface graphique native.

4. Coqui TTS [14]

Coqui TTS est un framework open source de synthèse vocale issu du projet Mozilla TTS. Il repose sur une architecture modulaire, cela signifie que le système est composé de plusieurs blocs indépendants (comme l’entraîneur de modèle, le vocodeur, le prétraitement), que l’on peut configurer, remplacer ou améliorer séparément en fonction des besoins. Cette approche offre une grande flexibilité pour l’expérimentation ou l’adaptation à un projet spécifique.

Nous recherchions une solution totalement libre, exécutable en local, permettant de personnaliser la voix sans dépendre d’une API tierce ni d’envois de données sensibles sur un serveur externe.

Résultat obtenu : La configuration de Coqui TTS s’est révélée plus accessible que celle de RTVC, avec une documentation claire et une installation relativement bien guidée. L’entraînement local demande néanmoins un certain temps et un GPU pour obtenir un rendu correct. La voix générée est intelligible et personnalisable, mais le résultat en français reste encore insatisfaisant en termes de fluidité et de naturel, surtout sans corpus d’entraînement spécifique ou ajustements avancés.

Points positifs :

- Entièrement gratuit et open source, large communauté.
- Configuration initiale modérément complexe mais plus accessible que d'autres outils open source comme RTVC.
- Possibilité de cloner ou d'affiner une voix en local (respect de la confidentialité).

Points négatifs :

- Qualité vocale moyenne sans approfondi et corpus conséquent.

Outil	Type	Points positifs	Points négatifs
PlayHT	En ligne (free-mium)	— Interface claire et facile à utiliser — Plusieurs voix et styles (surtout en anglais) — Génération rapide de fichiers audio	— Qualité médiocre en français — Peu d'options de personnalisation vocale — Accès limité dans la version gratuite — Pas d'intégration directe via API
ElevenLabs	En ligne (pro)	— Qualité vocale très élevée, proche d'une voix humaine réelle — Support du français avec bonne prosodie — Clonage efficace avec peu de données — Documentation complète et intégration possible via API	— Version gratuite limitée — Aucune option de clonage sans vérification

Outil	Type	Points positifs	Points négatifs
RTVC	Open source (Local)	— Clonage rapide avec peu de données — Code libre et modifiable — Exécutable en local sans API externe	— Qualité vocale robotique, surtout en français — Installation complexe avec dépendances
Coqui TTS	Framework open source	— Entièrement gratuit et open source — Installation plus accessible	— Qualité vocale moyenne en français

TABLE 1 – Comparaison des outils de clonage vocal testés

Modèles de synthèse vocale explorés mais non intégrés

Dans le cadre de notre étude des solutions de synthèse vocale, nous avons également exploré deux modèles de référence dans la littérature scientifique, Tacotron 2 et FastSpeech 2, bien que ces modèles n’aient pas été utilisés directement dans notre application, leur compréhension a permis de mieux situer les technologies actuelles dans le domaine du TTS (Text-to-Speech).

1. Tacotron 2 [15]

Tacotron 2 est un modèle de synthèse vocale autoregressif, dans lequel le spectrogramme est généré étape par étape, avant d’être converti en onde audio grâce à un vocodeur comme WaveGlow ou HiFi-GAN. Ce modèle, historiquement très influent, permet une qualité sonore élevée, notamment en anglais.

Toutefois, son implémentation nécessite un corpus conséquent et bien aligné (texte-audio), ainsi qu’un entraînement long sur GPU. De plus, son support natif pour le français est limité, ce qui rend son intégration plus complexe dans notre cas.

Avantages :

- Qualité vocale naturelle (en anglais)
- Modèle bien documenté et étudié dans la recherche
- Contrôle possible de la prosodie

Limites :

- Entraînement long et exigeant en ressources computationnelles
- Nécessite un vocodeur externe performant
- Peu adapté aux langues autres que l’anglais sans reentraînement spécifique

FastSpeech2 [16]

FastSpeech 2 est une évolution non autoregressive de la génération de spectrogrammes, un modèle produit l'ensemble des frames audio simultanément, ce qui accélère le traitement par le modèle. Il intègre également la modélisation de la prosodie (durée, hauteur, énergie), offrant un contrôle plus fin de l'intonation.

Comme Tacotron, il nécessite un vocodeur pour produire une onde sonore exploitable. L'entraînement d'un système complet repose sur un corpus de haute qualité et un calibrage technique rigoureux. En français, peu de modèles pré-entraînés sont disponibles, ce qui limite les applications directes.

Avantages :

- Synthèse très rapide
- Contrôle précis de la prosodie
- Potentiel élevé pour des applications expressives

Limites :

- Difficile à entraîner sur une nouvelle langue
- Nécessite des ressources importantes (données + GPU)
- Absence d'implémentations clé-en-main pour le français

Ces deux modèles représentent des solutions avancées en TTS, mais leur mise en œuvre dans notre projet aurait nécessité une phase d'entraînement complexe et des ressources (données, matériel) non disponibles dans notre contexte. Ils restent cependant des références pour toute démarche future visant à concevoir une synthèse vocale totalement personnalisée et open source.

Résultat final sur le clonage vocal

Il convient de souligner que des solutions telles que PlayHT n'ont pas été retenues pour l'implémentation finale. Bien qu'elles aient été testées, leur rendu en français restait trop robotique et leur interface offrait peu de contrôle sur l'intonation ou l'émotion, ce qui les rendait inadaptées à un usage direct dans l'application. Leur évaluation avait néanmoins un intérêt exploratoire notamment comprendre les approches employées par différents services de clonage vocal et mesurer rapidement la qualité obtenue.

Cette phase de test nous a permis de baliser le paysage technologique, de comparer les performances entre outils, et de confirmer que des solutions plus avancées telles que **ElevenLabs** étaient nécessaires pour atteindre le niveau de réalisme requis comme le meilleur compromis entre qualité, simplicité d'usage, et rendu naturel. Il a permis de générer une voix crédible à partir d'un court extrait de Jean Piaget, avec une bonne expressivité et une prononciation correcte du français.

Pour une version complémentent open source, des outils comme Coqui TTS ou FastSpeech 2 restent de très bonnes alternatives, mais nécessitent plus de temps et de ressources.

3.2 Synchronisation labiale et animation faciale

Dans l’objectif initial de créer un hologramme interactif de Jean Piaget, l’un des éléments fondamentaux consistait à animer son visage et l’ensemble de son corps de manière synchronisée avec la voix générée par l’IA. Cette synchronisation labiale entre l’audio et les mouvements de la bouche, accompagnée de gestes du visage ou du haut du corps, est un facteur clé pour créer l’illusion d’une interaction naturelle avec une figure incarnée. Elle ne se limite pas à un simple aspect esthétique, elle renforce la crédibilité du message, l’émotion perçue, et la sensation de présence.

Dans ce cadre, l’animation faciale ne devait pas seulement reproduire des mouvements arbitraires, mais refléter les intonations, les pauses et le rythme du discours synthétisé. L’objectif était de simuler une véritable conversation, dans laquelle l’image répond dynamiquement à la voix, comme si l’on dialoguait avec une personne réelle. Cette approche constitue un pont entre la synthèse vocale, la modélisation visuelle, et les technologies d’animation, et s’inscrit dans une volonté plus large d’humaniser les interfaces conversationnelles en leur donnant une forme et une expressivité visuelle.

Cependant, en l’absence de photographies de qualité du corps entier de Jean Piaget, nous avons choisi de concentrer notre travail sur l’animation de son visage uniquement. Cette limitation matérielle nous a amenés à explorer des solutions permettant de produire une animation faciale expressive à partir d’un simple portrait. Cela a guidé le choix des outils testés, notamment des modèles comme SadTalker ou Animate Anyone [17], capables de générer des mouvements réalistes du visage à partir d’une image fixe et d’un fichier audio.

L’idée était donc de transformer des données statiques (texte, image, voix) en une séquence vidéo crédible, incarnée et engageante, tout en s’affranchissant de la complexité de la modélisation corporelle complète.

Outils testés pour la synchronisation labiale et l’animation du visage

Plusieurs outils ont été explorés pour animer un visage à partir d’une photo, ou pour synchroniser les mouvements de la bouche avec une voix synthétique.

1. Wav2Lip [18]

Wav2Lip est un outil open-source basé sur un réseau de neurones profond, conçu pour synchroniser de manière réaliste les mouvements des lèvres d’un visage avec un fichier audio donné. Il a été largement adopté pour sa précision dans la synchronisation labiale, même dans des conditions visuelles sous-optimales.

Résultat : L’outil a donné d’excellents résultats en termes de synchronisation labiale à partir de la voix clonée de Jean Piaget. Le mouvement des lèvres est fluide et fidèle à l’audio, ce qui améliore considérablement le réalisme de l’animation faciale.

Points positifs :

- Synchronisation très précise des lèvres avec l’audio
- Open-source et facilement intégrable dans un pipeline personnalisé
- Fonctionne avec des vidéos ou images statiques

Points négatifs :

- Ne prend en charge que l’animation du visage être associé à d’autres outils pour produire une animation complète du visage et de la tête à partir du prétraitement

2. D-ID [19]

D-ID est une plateforme commerciale en ligne qui propose l’animation automatique d’une photo de visage à partir d’un texte ou d’un fichier audio. L’interface est simple et adaptée aux utilisateurs non techniques.

Résultat : L’outil permet de produire rapidement une vidéo animée d’un visage parlant. Cependant, le résultat peut manquer de naturel ou de précision dans la synchronisation labiale, surtout avec des voix non anglaises.

Points positifs :

- Utilisation rapide et intuitive
- Possibilité d’utiliser texte ou audio

Points négatifs :

- Résultat parfois artificiel
- Pas de personnalisation avancée
- Service payant avec usage limité en version gratuite

3. Vidnoz [20]

Vidnoz est une plateforme en ligne permettant de créer rapidement des avatars animés ou des vidéos à partir de textes ou d’enregistrements audio, en utilisant des modèles pré-entraînés. Elle propose aussi des fonctionnalités de clonage vocal et de lip-sync automatique sur une photo.

Outil accessible, idéal pour un test rapide de génération de visage animé avec synchronisation vocale.

Résultat : Le service a permis de générer une animation basique à partir d’une photo et d’un extrait audio. Cependant, la qualité de synchronisation labiale était limitée, et les mouvements restaient artificiels.

Points positifs :

- Facilité d’utilisation
- Intégration directe de la voix et l’animation faciale
- Rapide pour un premier prototype

Points négatifs :

- Pas de prise en charge de mouvements corporels
- Résultat peu naturel (synchronisation approximative)
- Limitations importantes dans la version gratuite
- Non compatible avec des modèles 3D personnalisés

4. SadTalker [21]

SadTalker est un outil open-source conçu pour générer des vidéos animées à partir d’une seule image et d’un fichier audio. Il se distingue par sa capacité à synchroniser non seulement les lèvres, mais aussi les mouvements de la tête et du visage, en tenant compte de l’intonation vocale. Il est largement utilisé dans des projets de synthèse faciale réaliste.

Architecture de SadTalker

SadTalker repose sur une architecture en deux modules principaux, un predictor de pose 3D et un générateur d’images animées. Le processus commence par l’analyse de l’audio fourni. Le modèle prédit ensuite une série de poses 3D de la tête (incluant les mouvements de rotation, d’inclinaison) synchronisées avec les caractéristiques de l’audio. Ces poses sont ensuite utilisées pour guider un générateur d’images basé sur un réseau GAN (général adversarial network), qui applique ces mouvements à l’image d’origine du visage.

Ce découplage entre la prédiction de pose et la génération visuelle permet d’obtenir une animation plus expressive et plus réaliste, notamment avec des mouvements de la tête et du haut du buste, ce que d’autres modèles comme Wav2Lip ne proposent pas. SadTalker intègre également un système de contrôle de la dynamique faciale, pour éviter des mouvements saccadés ou irréalistes, et améliorer la cohérence entre les expressions et la voix.

Résultat : SadTalker a été utilisé dans le pipeline final du projet. Il a permis d’obtenir une animation convaincante, synchronisée avec l’audio, donnant vie à une image statique grâce à des mouvements expressifs.

Points positifs :

- Synchronisation labiale précise et expressive.
- Animation de la tête et des traits du visage à partir d’une seule image.
- Outil open-source avec une communauté active.

Points négatifs :

- Installation complexe et configuration technique reste difficile.
- Résultat fortement dépendant de la qualité de la photo d’entrée.
- Pas de prise en charge des mouvements complets du corps.

5. MuseTalk [22]

MuseTalk est un modèle pour la génération de visages parlants. Il produit des vidéos réalistes en synchronisant les mouvements du visage avec l’audio, tout en permettant un contrôle plus fin sur la posture et les détails d’animation.

Architecture avancée de MuseTalk

MuseTalk se distingue des autres outils de synchronisation labiale par son architecture avancée, structurée en deux étapes. Plutôt que de générer directement l’animation à partir de l’audio, le

modèle commence par analyser la voix pour en extraire les éléments prosodiques, tels que le rythme, l'intonation ou les pauses. Cette analyse permet de générer une séquence d'expressions faciales intermédiaires, qui sont ensuite converties en une animation vidéo complète, incluant les mouvements de la bouche, des yeux et de la tête. Ce découpage du traitement permet une synchronisation plus précise et plus fluide, en particulier sur des visages statiques ou des images de qualité moyenne. L'animation produite est ainsi plus expressive, plus stable, et mieux adaptée à des contenus vocaux variés. Grâce à cette approche, MuseTalk offre une solution performante pour obtenir des résultats réalistes dans des contextes comme le nôtre, où la qualité de l'image et de la voix peut être variable.

Résultat : MuseTalk a été intégré dans le backend de l'application pour générer les animations finales lorsque la vidéo est demandée. Il a fourni une synchronisation fluide et des expressions naturelles à partir d'une photo et d'un fichier audio, avec de meilleures performances que certains outils plus anciens.

Points positifs :

- Qualité d'animation supérieure, plus stable et expressive que SadTalker.
- Contrôle possible sur les mouvements de la tête et la posture.
- Fonctionne bien avec un large éventail d'entrées audio.

Points négatifs :

- Plus récent, donc moins documenté que SadTalker.
- Nécessite une configuration GPU pour des résultats optimaux.
- Moins simple à intégrer sans wrapper ou interface dédiée.

Outil	Type	Points positifs	Points négatifs
Wav2Lip	Open-source	Très bonne synchronisation des lèvres, fonctionne avec tout audio, réaliste pour le visage	Pas d'animation du corps, nécessite un bon cadrage facial
D-ID	Plateforme en ligne	Facile à utiliser, génération rapide de vidéo	Animation parfois artificielle, peu de contrôle
Vidnoz	Plateforme gratuite	Animation faciale fluide, interface simple	Pas d'animation corporelle, pas de support 3D
SadTalker	Open-source	Animation expressive (visage, tête, buste), bonne synchronisation	Dépend fortement de l'image, configuration avancée
MuseTalk	Open-source	Synchronisation fluide, mouvements naturels de la tête, meilleure stabilité avec l'audio	Moins documenté, nécessite une configuration technique avancée

TABLE 2 – Résumé des outils de synchronisation labiale et d'animation faciale

Résultat final sur les outils de synchronisation labiale et d'animation faciale

Après avoir exploré ces solutions, SadTalker et MuseTalk se sont révélés les plus proches de nos besoins dans le cadre du projet.

SadTalker a été choisi pour sa capacité à produire une animation complète du visage, avec des mouvements naturels de la tête et une synchronisation labiale précise, à partir d'un unique fichier image et audio. Son intégration open source, bien documentée et flexible, en a fait un outil central dans notre pipeline de génération vidéo.

MuseTalk, plus récent, a été intégré en complément pour améliorer encore la qualité de la synchronisation labiale. Grâce à son architecture avancée, il permet de générer des mouvements plus fluides, avec une attention particulière portée à la cohérence audio-visuelle. Il a été utilisé comme étape de raffinement final dans la génération de la vidéo animée.

L'association de ces deux outils nous a permis de surmonter les limites liées à l'absence de modèle 3D complet, tout en obtenant une animation faciale crédible, engageante et techniquement satisfaisante pour simuler une interaction humaine avec Jean Piaget.

Dans notre projet, nous avons utilisé SadTalker via l'API proposée par la plateforme Fal.ai. Cette API offre une solution simplifiée pour animer un visage à partir d'une image et d'un fichier audio, tout en intégrant une synchronisation labiale réaliste. En réalité, le service repose sur une combinaison optimisée de SadTalker et MuseTalk, permettant de générer des vidéos où les mouvements du visage (lèvres, yeux, tête) sont fluides, expressifs et bien synchronisés avec la voix générée. Cette intégration nous a permis d'obtenir un rendu visuel crédible sans avoir à gérer manuellement les deux outils en local, ce qui simplifie grandement l'implémentation tout en conservant une qualité d'animation satisfaisante.

3.3 Exploration de la piste 3D

Dans l'objectif initial de créer un hologramme interactif réaliste de Jean Piaget, nous avons étudié la possibilité de générer un modèle 3D complet de son visage et de son corps. L'idée était de renforcer la présence numérique du personnage en produisant des animations corporelles naturelles en plus de l'animation faciale.

Outils testés :

HeyGen [23]

Plateforme en ligne populaire pour la création d'avatars vidéo réalistes, utilisée dans le cadre d'animations de présentation ou de communication numérique.

Résultat : L'outil permet effectivement de générer un avatar animé à partir d'un texte ou d'un enregistrement vocal, avec une synchronisation labiale convaincante. Toutefois, la création d'un avatar fidèle nécessite une vidéo source de bonne qualité, ce qui n'était pas disponible dans le cas de Jean Piaget.

Points positifs :

- Interface intuitive et accessible
- Qualité d’animation réaliste pour le visage
- Utilisable directement en ligne

Points négatifs :

- Nécessite une vidéo nette et récente pour créer un avatar personnalisé
- Impossible de générer un avatar à partir d’une seule photo
- Fonctionnalités limitées dans la version gratuite

VoxCraf [24], poly.cam [25], LumaLabs [26]

Ces outils permettent de générer un modèle 3D à partir de plusieurs images, ce qui constitue une approche intéressante pour reconstruire un visage ou un corps en trois dimensions à partir de documents visuels existants.

Résultat : Les résultats ont été peu concluants dans notre cas. Les outils fonctionnent correctement avec des jeux d’images variés et bien éclairés, mais les photos historiques disponibles de Jean Piaget sont trop limitées en nombre et en qualité pour produire un rendu 3D satisfaisant.

Points positifs :

- Technologie innovante basée sur la photogrammétrie
- Accessible en ligne, parfois directement depuis un smartphone
- Potentiel élevé avec des images bien adaptées

Points négatifs :

- Requiert plusieurs images sous différents angles
- Fortement dépendant de la qualité des photos sources
- Non adapté aux figures historiques avec peu de documents visuels

MetaHuman (Epic Games) [3]

MetaHuman est un outil de référence développé par Epic Games pour créer des personnages 3D très réalistes avec un haut niveau de personnalisation.

Résultat : La qualité de rendu est impressionnante, et les options de personnalisation sont nombreuses. Toutefois, l’outil ne permet pas de générer automatiquement un avatar fidèle à partir d’une photo réelle et il faut les concevoir entièrement depuis zéro, ce qui limite son usage dans notre contexte.

Points positifs :

- Qualité graphique très élevée
- Interface complète avec nombreuses options de personnalisation
- Intégration possible avec Unreal Engine pour des usages avancés

Points négatifs :

- Impossible de créer automatiquement un avatar fidèle à partir d’une photo
- Nécessite un matériel puissant pour un usage fluide

DeepMotion [27]

DeepMotion est une solution basée sur l'intelligence artificielle permettant de générer des mouvements de corps à partir d'une vidéo. Cela offrait une piste intéressante pour animer le corps entier d'un personnage.

Résultat : Les résultats sont réalistes lorsque les vidéos sources sont de bonne qualité. Cependant, dans notre cas, l'absence de vidéo exploitable de Jean Piaget a limité fortement l'intérêt de cette solution.

Points positifs :

- Génération automatique de mouvements corporels à partir d'une simple vidéo
- Rendu fluide et crédible dans de bonnes conditions

Points négatifs :

- Requier des vidéos de haute résolution avec une bonne capture des mouvements
- Peu utile dans le cas de personnages historiques sans vidéo disponible
- Modèle payant pour un usage avancé

Ready Player Me [28]

Ready Player Me est une plateforme en ligne permettant de générer rapidement un avatar 3D personnalisable à partir d'une photo ou d'un modèle préexistant. Elle propose une solution accessible pour créer un personnage numérique exploitable dans diverses applications.

Résultat : L'outil permet effectivement de générer un avatar en quelques étapes, avec un bon rendu visuel, mais les possibilités de personnalisation restent limitées, et il n'est pas possible d'obtenir un double fidèle d'une personne réelle. De plus, l'avatar généré n'est pas immédiatement utilisable pour une animation vocale réaliste.

Points positifs :

- Génération rapide et intuitive d'avatars 3D
- Intégration possible avec de nombreuses plateformes et moteurs (Unity, Web)
- Solution gratuite avec options commerciales

Points négatifs :

- L'avatar ne reflète pas fidèlement une personne réelle
- Peu de contrôle sur les détails du visage
- Non adapté pour une animation labiale ou émotionnelle avancée

Outil	Avantages	Limites
HeyGen	Génère un avatar 3D animé à partir d'un texte ou d'un enregistrement vocal. Résultat fluide et réaliste avec de bonnes vidéos.	Nécessite une vidéo de bonne qualité pour créer un avatar fidèle. Peu adapté à partir de photos anciennes.
VoxCraft, poly.cam, Luma-Labs	Permettent de créer un modèle 3D à partir de plusieurs images. Bonne intégration avec des environnements 3D.	Les images anciennes de Piaget sont souvent de mauvaise qualité ou trop peu nombreuses, ce qui affecte la fidélité du rendu.
MetaHuman (Epic Games)	Création et personnalisation d'avatars 3D très réalistes. Grande flexibilité dans les détails physiques.	Ne permet pas d'importer directement une vraie photo pour générer un modèle personnalisé fidèle. Nécessite des compétences techniques.
DeepMotion	Génère les mouvements du corps à partir d'une vidéo. Compatible avec des modèles 3D existants.	Requiert une vidéo en haute qualité avec le corps entier. Outil payant avec restrictions en version gratuite.
Ready Player Me	Création facile d'avatars 3D, SDK disponible	Pas de personnalisation à partir d'une simple photo

TABLE 3 – Outils explorés pour la création de modèles 3D

Résultat final : abandon temporaire de la piste 3D

La principale difficulté réside dans le manque de données visuelles exploitables, les rares photos disponibles ne montrent pas l'ensemble de son corps sous différents angles, ce qui rend la modélisation et l'animation en trois dimensions peu fiables. En raison de ces limitations, et compte tenu des ressources techniques que nécessiterait une telle reconstruction, nous avons opté pour une solution plus accessible et réaliste, l'animation en 2D d'une photo du visage, associée à une synchronisation labiale précise. Cette alternative permet de préserver une forme de présence visuelle crédible, tout en restant techniquement réalisable.

3.4 Traitement du langage naturel (NLP) pour la conversation

Le fonctionnement de l'interaction vocale dans notre application repose sur un enchaînement coordonné de modules. D'abord, la voix de l'utilisateur est capturée, ensuite transcrite automatiquement en texte grâce à un système de reconnaissance vocale (speech-to-text). Le texte obtenu

est analysé par un modèle NLP, qui génère une réponse appropriée en fonction du contexte ou des documents fournis. La réponse textuelle est ensuite transformée en voix synthétique à l'aide d'un système de synthèse vocale (TTS), en utilisant par exemple une voix clonée. Enfin, cette réponse vocale est synchronisée avec les mouvements des lèvres de l'avatar, créant ainsi une animation réaliste et immersive pour l'utilisateur.

Outils testés et comparés

- **Rasa** : framework open-source pour créer des chatbots basés principalement sur des réponses préprogrammées.
Limites : Cela implique de définir à l'avance les types de questions et les réponses associées, ce qui ne correspond pas à la nature ouverte et générative de notre projet. De plus, son déploiement local nécessite des ressources matérielles importantes, ce qui dépassait nos capacités.
- **Ollama** : plateforme prometteuse pour exécuter localement des LLMs (comme LLaMA, Mistral).
Limites : problèmes de compatibilité matériel, modèles volumineux à faire tourner en local.
- **OpenAI (GPT-4)** : modèle NLP avancé, capable de répondre de façon fluide et contextuelle, avec une excellente compréhension linguistique.
Limites : non gratuit, mais facilement utilisable via API, avec une qualité exceptionnelle.

Outil	Type	Points positifs	Limites
OpenAI (GPT-4)	API cloud (propriétaire)	Très bonne compréhension du langage, réponse fluide, multilingue, facile à intégrer	Payant, dépendance à une API externe
Rasa	Framework open-source	Complètement personnalisable, open-source, adapté aux données internes	Installation complexe, demande beaucoup de ressources
Ollama	Exécution locale de LLMs	Permet de faire tourner des LLMs en local, respecte la vie privée	Demande une machine puissante, certains modèles peu optimisés

TABLE 4 – Comparaison des outils NLP testés pour la conversation

Résultat final sur le NLP

En raison de ressources matérielles limitées ne permettant pas l'exécution locale d'un modèle de langage de grande taille, nous avons fait le choix d'utiliser l'API d'OpenAI. Cette solution offre

des réponses cohérentes, fluides et multilingues, tout en permettant l'enrichissement des capacités du modèle par l'ajout de documents personnalisés grâce à la méthode RAG (Retrieval-Augmented Generation).

3.5 Génération de Vidéo à partir d'une Photo, d'une Voix et d'un Texte

Nous avons exploré plusieurs outils permettant de transformer une simple photo en une vidéo animée, afin de synchroniser les mouvements du visage (et idéalement de la tête) avec le texte généré par OpenAI et la voix clonée.

1. Ray2Flash (fal.ai) [29]

Ray2Flash est un modèle d'animation avancé proposé via la plateforme Fal.ai, qui combine des techniques de génération de mouvements corporels et faciaux réalistes à partir d'une simple image. Le modèle repose sur des réseaux de neurones récents, de type transformer (pour comprendre et générer du texte) ou diffusion (pour créer des images ou vidéos à partir de bruit aléatoire), ça permet de générer une vidéo entière animée à partir d'une image unique, en s'appuyant sur un fichier audio (voix clonée) ou une commande textuelle transformée en voix, avec un résultat cohérent au niveau du mouvement du corps, de la tête et des lèvres.

Résultats observés :

- La qualité du résultat dépend fortement de la photo d'entrée, les images bien éclairées, de face et neutres donnent de bien meilleurs rendus.
- Les mouvements générés concernent principalement la tête et le visage, les mouvements corporels restent limités ou absents.
- Des défauts visuels peuvent apparaître si la photo est trop modifiée ou de mauvaise qualité.
- Le modèle nécessite une connexion à l'API Fal.ai, impliquant une dépendance externe et une latence.
- Le temps de génération est variable (jusqu'à 1 à 2 minutes selon la complexité), ce qui peut ralentir l'expérience utilisateur en temps réel.

2.D-ID [5]

D-ID est une plateforme très populaire dans le domaine de l'animation faciale à partir de texte ou d'audio. Elle repose sur des modèles propriétaires permettant, une animation faciale fluide avec expressions et synchronisation labiale.

Limite : D-ID bloque automatiquement les photos de personnalités publiques, détectant le visage de Jean Piaget comme "sensible", ce qui rend l'outil inutilisable dans notre contexte.

3.Face-api [30]

Il s'agit d'une bibliothèque JavaScript permettant la détection de points faciaux (yeux, nez, bouche, menton), le suivi en temps réel de l'orientation du visage via webcam.

Limite : Cette bibliothèque est principalement conçue pour détecter et suivre en temps réel les mouvements du visage via webcam, mais elle ne permet pas de générer des animations vidéo à partir d'un fichier audio ou d'un texte. Elle est donc utile comme complément pour le suivi de l'orientation du visage dans des interfaces interactives en direct, mais ne répond pas aux besoins d'animation automatique d'un visage à partir d'une image fixe.

4. Poly.cam, VoxCraft, DeepBrain

Ces outils appartiennent à la catégorie des créateurs de personnages 3D. Ils permettent de concevoir des avatars très détaillés (forme du visage, morphologie), toutefois, ils exigent généralement plusieurs angles de vue ou une modélisation manuelle.

- **Poly.cam** [25] : application de scan 3D via smartphone, peu adaptée lorsqu'on ne dispose que d'une image historique.
- **VoxCraft** [24] : moteur 3D simple, offrant un rendu peu réaliste et très basique.
- **DeepBrain** [31], **MetaHuman** [32] : solutions avancées, néanmoins fermées ou non compatibles avec l'importation directe d'un vrai visage.

Outil	Points positifs	Limites
Ray2Flash (fal.ai)	Animation complète de l'image (pas seulement le visage)	Animation parfois peu naturelle, limites esthétiques
D-ID	Vidéo générée à partir de texte ou audio, interface simple	Interdiction d'utiliser des visages de personnes connues
face-api.js	Détection en temps réel des landmarks faciaux	Ne produit pas de vidéo animée, juste détection
DeepBrain	Plateforme performante pour animation vocale	Accès restreint aux visages célèbres, payant

TABLE 5 – Comparatif des outils de génération de vidéo animée à partir d'une photo

Limites rencontrées

- La qualité de la photo de départ est déterminante, il faut un visage net, bien cadré, sans ombre ni flou.
- Très peu d'outils permettent une synchronisation labiale réaliste avec l'audio d'entrée, sans artefact visuel.
- Les outils 3D ne fonctionnent pas avec une simple photo, ils demandent des données volumétriques ou des scans.
- Les solutions vraiment réalistes sont payantes, complexes à intégrer, et parfois fermées à l'usage libre.
- Les temps de traitement (jusqu'à 2 minutes par réponse animée) freinent les cas d'usage en conversation fluide, notamment dans un contexte de projection holographique.

Résultat final sur la génération de Vidéo

Nous avons finalement choisi d'utiliser une combinaison de :

- SadTalker + MuseTalk pour générer la vidéo faciale animée
- Ray2Flash pour un mouvement global de l'image
- une voix clonée par ElevenLabs pour la synchronisation labiale

Utilisation de Fal.ai : Fal.ai est une plateforme de média génératif conçue pour les développeurs. Elle permet d'exécuter des modèles d'IA de génération comme Ray2Flash ou SadTalker à travers des APIs performantes et des interfaces interactives. Elle facilite l'intégration rapide de modèles complexes sans avoir à gérer leur hébergement ou leur déploiement.

Cette solution reste accessible via cette API en ligne qui permet de produire une vidéo animée cohérente à partir d'une photo et d'une réponse vocale générée dynamiquement, bien que l'accès à l'ensemble de ses capacités requiert néanmoins un abonnement.

4 Méthodologie et mise en œuvre

4.1 Objectifs fonctionnels et techniques

L'ambition du projet est de développer une application interactive capable de simuler un échange crédible avec une figure scientifique, en combinant intelligence artificielle, synthèse vocale et animation visuelle. Les objectifs se sont progressivement affinés à travers les phases de conception et de tests, en intégrant des contraintes techniques réelles et les retours issus des expérimentations. L'enjeu était de créer une interaction capable de donner des réponses justes tout en rendant l'échange vivant et naturel.

Objectifs fonctionnels

- Offrir une interface web interactive permettant aux utilisateurs de discuter avec un personnage scientifique, par oral ou par écrit, depuis un simple navigateur.
- Permettre aux utilisateurs de créer un personnage à incarner, en chargeant une image et un extrait vocal permettant le clonage de la voix.
- Générer des réponses pertinentes à partir d'un modèle de langage, en s'appuyant non seulement sur les connaissances générales, mais aussi sur des documents fournis par l'utilisateur (biographies, articles, pages web), via une logique RAG (Retrieval-Augmented Generation).
- Animer une photo (image statique) du personnage de manière réaliste, en synchronisant les mouvements des lèvres, du visage et éventuellement de la tête avec la voix synthétique générée à partir du texte.
- Générer une vidéo animée du personnage répondant vocalement à l'utilisateur, lorsque celui-ci choisit le mode vocal avec image.

- Permettre à l'utilisateur de sélectionner :
 - Le type de chat (scientifique, historique, éducative)
 - La langue de l'échange (français ou anglais)
 - Le type d'interaction (texte seul, audio, ou vidéo avec photo animé)
- Proposer une option de chargement de documents personnels (PDF, site web, articles) afin d'alimenter les réponses du personnage avec des sources fiables choisies par l'utilisateur.

Objectifs techniques

- Intégrer différents modules (NLP, TTS, RAG, animation) dans un pipeline unifié signifie concevoir une architecture dans laquelle chaque composant communique avec les autres, de façon à produire automatiquement une sortie multimodale cohérente à partir d'une simple entrée utilisateur.
- Connexion et utilisation d'APIs performantes telles que celles proposées par OpenAI (GPT), ElevenLabs, SadTalker avec MuseTalk, ou encore Ray2Flash, afin d'assurer la génération de contenu vocal, textuel et visuel de manière intégrée.
- Assurer la synchronisation entre texte, voix et animation faciale.
- Garantir des performances en temps réel (génération vocale et animation).
- Fonctionner à partir de données limitées (image unique, voix extraite d'une vidéo).
- Préparer une architecture modulable et extensible pour intégrer d'autres personnages ou types de contenus.

Enjeux pour une interaction fluide et réaliste

- La qualité de la voix générée, en particulier pour reproduire fidèlement celle de Jean Piaget.
- La fluidité et la précision des mouvements de tête et de lèvres lors de la génération vidéo.
- La fiabilité des réponses fournies par le système RAG, c'est-à-dire leur cohérence avec les documents fournis.
- La réponse est alignée avec la voix et l'image du personnage sélectionné (lorsqu'une vidéo est générée).
- L'interface est stable, ergonomique et compréhensible sans formation.
- Le contenu généré respecte le style et la pensée du scientifique sélectionné.
- La rapidité de génération vidéo, indispensable pour maintenir une interaction fluide et réaliste dans un cadre de conversation en temps réel. Idéalement, la vidéo animée du personnage devrait être produite en quelques secondes afin de ne pas casser le rythme du dialogue.

4.2 Architecture du système

L'architecture de notre application repose sur une séparation claire entre le **frontend** (interface utilisateur), le **backend** (traitement des requêtes, orchestration), et l'intégration de plusieurs **API externes** (OpenAI, ElevenLabs, Fal.ai). Cette organisation modulaire permet de traiter de manière fluide des requêtes multimodales combinant texte, voix, image et vidéo.

1. Frontend (React) L'interface utilisateur, développée avec **React**, repose sur trois pages principales :

- **HomePage** : saisie du nom et de la personnalité, clonage de la voix, ajout de sources de connaissance (document ou URL), et upload d'une photo.
- **AvatarPage** : génération d'un avatar via un prompt grâce à DALL·E.
- **ChatPage** : interface de dialogue vocal ou textuel avec l'avatar, affichage des réponses sous forme de texte, audio ou vidéo.

Ces pages font appel aux services suivants :

- `dalleservice.js` : communication avec DALL·E pour générer des avatars.
- `document.js` : envoi de documents ou URL au backend pour le système RAG.
- `falUpload.js` : upload de fichiers audio ou image vers le backend pour Fal.ai (SadTalker, Ray2Flash).

2. Backend (FastAPI) Le backend est structuré en deux dossiers :

- `api` : routes FastAPI pour les fonctionnalités principales (avatar, chat, vidéo, clonage vocal, RAG).
- `services` : fonctions métiers internes (lecture de documents, embeddings, synthèse vocale, gestion des voix).
- **Modules API** :
 - `chat.py` : génère les réponses via GPT-4 selon le type de chat, le prompt personnalisé, et les documents chargés (RAG).
 - `clonevoice.py` : interagit avec ElevenLabs pour créer un `voice_id`.
 - `avatar.py` : utilise DALL·E pour générer ou modifier un avatar.
 - `generate-video.py` : envoie image et audio à Ray2Flash puis MuseTalk pour produire une vidéo animée.
 - `fal-proxy.py` : proxy générique vers Fal.ai (SadTalker, MuseTalk...).
 - `upload-doc.py`, `scrape-url.py` : envoient des documents ou des URL au module RAG.
 - `voice.py` : convertit du texte en audio avec ElevenLabs.
- **Modules Services** :
 - `document-reader.py` : extrait du texte depuis des fichiers ou des pages web.
 - `embedding.py` : vectorise le texte avec OpenAI ADA pour recherche FAISS.
 - `voice-synthesizer.py` : génère de l'audio à partir de texte et d'un `voice_id`.
 - `voiceStorage.py` : enregistre les voix clonées de chaque utilisateur.

3. APIs externes

- **OpenAI** : GPT-4 pour la génération de réponses, DALL·E pour la génération d'avatar, ADA pour l'embedding de texte (RAG).
- **ElevenLabs** : clonage vocal et génération de voix en plusieurs langues.
- **Fal.ai** : génération de vidéo avec Ray2Flash, synchronisation labiale avec MuseTalk et SadTalker.

Communication des composants

- Le frontend interagit avec le backend via des requêtes HTTP (`fetch( )`).
- Le backend traite la requête, appelle les APIs externes, et renvoie une réponse adaptée (texte, audio ou vidéo).
- L'interface utilisateur se met à jour dynamiquement en fonction du format de réponse.

Le schéma suivant illustre cette architecture globale et l'enchaînement des composants :




FIGURE 1 – Architecture générale de l'application




FIGURE 2 – Architecture détaillé de l'application

Fonctionnement global de l'application :

Le déroulement d'interaction suit les étapes suivantes :

1. L'utilisateur saisit un personnage (nom, image, voix).
2. Il pose une question à l'oral ou à l'écrit. Si la question est posée à l'oral, elle est transcrite automatiquement en texte (reconnaissance vocale).
3. La question est traitée par un modèle GPT, éventuellement enrichi via RAG.
4. Une réponse est générée, transformée en audio puis animée si une image est fournie.
5. Le résultat (texte, audio ou vidéo) est renvoyé à l'interface utilisateur.
6. L'interface permet également de sélectionner le type de chat souhaité.

7. Un champ optionnel permet à l'utilisateur de définir un prompt personnalisé qui sera injecté dans le système NLP pour moduler le style des réponses.
8. Il peut générer un avatar à partir d'un prompt textuel.

4.3 Méthodologie de développement

Le développement du projet a suivi une approche exploratoire fondée sur l'expérimentation progressive des technologies disponibles. Plutôt que de s'appuyer sur un cadre fixe dès le départ, nous avons avancé par itérations, en testant différents outils pour chaque composant clé de l'application.

Cette méthodologie nous a permis de comparer concrètement les performances, la compatibilité et les limites de chaque solution dans un contexte réaliste d'usage. Chaque choix technique a été guidé par des critères précis notamment accessibilité, qualité du rendu, facilité d'intégration, et adéquation avec les objectifs pédagogiques et interactifs du projet.

Ainsi, la structure finale de l'application s'est construite progressivement, en capitalisant sur les retours des tests, en adaptant les composants retenus et en assurant leur cohérence au sein d'un système global unifié.

Exploration initiale et cadrage : après une première phase de recherche, nous avons identifié les domaines techniques essentiels tels que la synthèse vocale, le clonage de voix, l'animation faciale, la génération de réponses par IA et création d'avatars. Ces domaines ont servi de base pour orienter notre méthodologie. Le choix de Python pour le backend s'est imposé naturellement, car il permet de connecter et faire fonctionner tous les outils IA (NLP, TTS, animation) ensemble, rapidement et efficacement via une API moderne comme FastAPI.

Prototypage rapide des outils : chaque outil a été expérimenté séparément, dans une logique de veille technologique et de validation rapide des possibilités. Nous avons exploré plusieurs solutions pour la synthèse vocale, la reconnaissance vocale, l'animation d'image, la génération d'avatars, et le traitement du langage naturel. Tous ces outils n'ont pas été intégrés dans l'application finale, seuls ceux qui offraient une qualité satisfaisante, une compatibilité avec nos contraintes techniques, et une orientation claire vers nos objectifs ont été retenus et implémentés dans le prototype final.

Évolution du besoin et élargissement du projet : partant d'un objectif centré sur Jean Piaget, le projet a progressivement évolué vers une plateforme ouverte, capable d'incarner différentes figures scientifiques selon le choix de l'utilisateur. Cette évolution a fait émerger de nouveaux besoins, permettre la sélection de la langue (français ou anglais), le type d'interaction (scientifique, historique, général), la personnalisation du comportement via des prompts, la génération d'un avatar à partir d'une description textuelle, ainsi que l'ajout de documents ou liens web pour enrichir les réponses fournies par le chatbot (RAG).

Construction progressive d'une architecture modulaire : au fil des expérimentations, nous avons progressivement structuré le projet autour d'un backend en Python (FastAPI) et d'un frontend en React. Chaque outil validé (pour la voix, le texte, l'image ou l'animation) a été intégré au fur et à mesure sous forme de module indépendant, accessible via une route API dédiée. Cette organisation modulaire nous a permis d'avancer étape par étape, en adaptant l'architecture aux besoins émergents.

Intégration progressive et scénarios d’usage : nous avons intégré les composants progressivement en fonction de scénarios concrets comme utilisateur avec ou sans image, en français ou en anglais, avec des documents ou non, en mode texte ou vocal. Cette logique a permis de valider les interactions les plus fréquentes et de prévoir des extensions futures.

Tests internes et ajustements continus : tout au long du développement, nous avons réalisé des tests réguliers pour vérifier le bon fonctionnement des modules et leur intégration. Ces essais nous ont permis d’identifier et corriger des erreurs techniques (API, temps de réponse, compatibilité), d’optimiser certains processus, et d’améliorer l’ergonomie générale de l’application.

Cette méthode exploratoire, guidée par l’expérimentation concrète et l’évolution des besoins, a permis d’assembler un prototype fonctionnel et cohérent à partir d’outils variés, tout en conservant une grande flexibilité technique.

4.4 Implémentation par modal

4.4.1 Organisation du code et modules utilisés

L’implémentation de notre application repose sur une architecture modulaire. Chaque module fonctionnel est pris en charge par des composants spécifiques, organisés en dossiers et fichiers selon leur rôle dans le système.

Frontend (React) Le frontend est structuré pour permettre l’interaction utilisateur via une interface fluide. Il comprend :

- **Context** : `avatarContext.js` et `VoiceContext.js` permettent de centraliser la gestion de l’état global (voix, avatar) via React Context API.
- **Services** : `dalleservice.js`, `document.js`, `falupload.js` regroupent les fonctions pour interagir avec les API externes ou le backend (upload de document, génération d’images, communication avec Fal.ai).

Backend (FastAPI) Le backend expose différentes routes correspondant aux grandes fonctionnalités du système. Il est divisé en deux dossiers, les **APIs** et les **services**.

API :

- `avatar.py` : gestion de la génération ou modification de l’avatar.
- `chat.py` : génération des réponses (GPT-4), en tenant compte du prompt système, du type de chat, du prompt personnalisé et des données RAG.
- `clonevoice.py` : envoie l’audio à ElevenLabs, récupère le *voice_id* et l’utilise pour synthétiser les réponses.
- `fal-proxy.py` : agit comme relais pour envoyer les images et audio vers l’API Ray2Flash (Fal.ai).
- `generate-video.py` : lance la génération vidéo en combinant SadTalker et Ray2Flash.
- `scrape-url.py` : extrait le texte d’un site web pour l’injecter dans la base RAG.
- `upload-doc.py` : traite les fichiers PDF ou TXT et les prépare pour l’indexation RAG.

— `voice.py` : gère la reconnaissance vocale et la synthèse textuelle.

Services :

- `document-reader.py` : extrait et nettoie le contenu textuel des fichiers et pages web.
- `embedding.py` : transforme le texte en vecteurs pour FAISS (RAG).
- `voice-synthesizer.py` : envoie les textes à ElevenLabs avec le *voice_id* pour synthèse vocale.
- `voiceStorage.py` : stocke les voix clonées associées à chaque utilisateur/personnage.

4.4.2 Processus d'implémentation détaillé

Cette partie détaille concrètement l'implémentation technique du projet, en décrivant comment chaque composant technologique a été intégrée au sein du système. L'approche adoptée a été modulaire ce qui signifie que chaque composant (voix, image, texte, vidéo, RAG) a été codé dans un fichier ou module dédié, puis connecté aux autres via des routes API REST. Nous détaillons ici les principales étapes de mise en œuvre.

1. Voix et synthèse vocale

Avant de pouvoir cloner la voix de Jean Piaget, il fallait d'abord obtenir un extrait sonore exploitable. Pour cela, nous avons utilisé **Audacity**, un logiciel libre d'édition audio. En se basant sur un enregistrement audio d'archive, nous avons pu isoler environ trois minutes de voix parlée, sans bruit de fond important. Ce fichier a servi de base pour tester les différents outils de clonage.

Une fois l'extrait audio préparé, parmi les solutions testées (comme détaillé précédemment), **ElevenLabs** a permis d'obtenir une voix synthétique de bonne qualité, proche de la voix originale et adaptée au français.

Le fonctionnement de l'API ElevenLabs repose sur deux étapes principales :

- **Clonage de la voix** : l'utilisateur téléverse un extrait vocal (au format .mp3 ou .wav) via une requête `POST` sur l'API. Cet enregistrement sert à créer un *voice_id*, qui représente une version synthétique de la voix originale.
- **Utilisation de la voix clonée** : à chaque fois qu'une réponse textuelle est générée par GPT, ce texte est envoyé à l'API ElevenLabs en spécifiant le *voice_id*. L'API retourne alors un fichier audio (.mp3) où le texte est lu avec la voix clonée.

Ce fichier audio est ensuite soit joué directement dans l'interface, soit utilisé comme entrée pour la génération vidéo avec SadTalker. Le *voice_id* peut être réutilisé à tout moment pour continuer à parler avec la même voix.

2. Modèle conversationnel et génération de réponses

Pour comprendre les questions posées par l'utilisateur et générer des réponses cohérentes dans le style de Piaget, nous avons utilisé OpenAI GPT-4, capable de produire des réponses contextuelles en s'appuyant sur les écrits du psychologue.

L'interaction se fait en mode **voice-to-voice** :

- **Reconnaissance vocale (Speech-to-Text)** : L'utilisateur peut poser sa question à l'oral grâce à la reconnaissance vocale intégrée au navigateur. Cette fonctionnalité repose sur l'API native **SpeechRecognition**, qui permet de transcrire la parole en texte directement dans le navigateur, sans passer par un serveur ou un service cloud externe. Elle utilise les capacités internes du navigateur (comme celles de Google Chrome) pour capter, analyser et convertir la voix en texte. Bien qu'elle soit moins précise que des solutions avancées comme Whisper d'OpenAI, elle présente l'avantage d'être légère, rapide et facile à intégrer. Cette solution est donc adaptée à des requêtes courtes, dans un environnement calme. Une fois la transcription effectuée, le texte est transmis au backend pour traitement par le modèle conversationnel.
- **Analyse du texte (NLP)** : le texte obtenu est ensuite transmis à une autre route FastAPI qui appelle l'API GPT-4. Ce modèle génère une réponse en langage naturel, selon le type de chat choisi.
- **Synthèse vocale (Text-to-Speech)** : le texte généré est envoyé à ElevenLabs avec un identifiant de voix (`voice_id`). L'API retourne un fichier audio où le texte est lu avec la voix clonée du personnage.
- **Restitution au frontend** : ce fichier audio est renvoyé à l'interface, puis lu automatiquement dans le navigateur. Si une image est également fournie, une vidéo peut être générée pour rendre l'interaction encore plus immersive.

Deux options supplémentaires permettent d'affiner la génération :

- **Le type de chat** : l'utilisateur peut choisir entre plusieurs styles de conversation (scientifique, historique ou éducatif). Ce choix modifie dynamiquement le prompt système utilisé pour guider GPT-4.
- **Le prompt personnalisé** : l'utilisateur peut également entrer manuellement une instruction spécifique (ex. : "Réponds comme un professeur de lycée", ou "Sois plus bref").

Cette personnalisation est intégrée au début du prompt, avant sa transmission à l'API.

Côté backend, ces choix sont traités dans le fichier `chat.py`. Lorsqu'une question est reçue, le serveur construit dynamiquement un prompt complet qui combine :

- le système prompt de base (ex. : "Tu es Jean Piaget, psychologue suisse...")
- l'option de type de chat sélectionnée
- le prompt personnalisé éventuellement fourni par l'utilisateur
- La question finale qui a été posée

Ce prompt est ensuite transmis à l'API OpenAI avec un contexte optionnel (issus du RAG s'il y a un document chargé), et la réponse générée est retournée pour être vocalisée ou animée selon les paramètres définis.

Si un document a été fourni (PDF ou site web), il est d'abord traité (conversion en texte, nettoyage) pour en extraire des passages pertinents via un système RAG. Le prompt est

ensuite enrichi selon le type de chat sélectionné. GPT produit une réponse cohérente et contextualisée, qui est retournée au frontend pour affichage ou conversion vocale.

3. Intégration des documents et RAG [33]

Pour améliorer la pertinence des réponses générées par l’agent conversationnel, nous avons intégré un système de type **RAG** (*Retrieval-Augmented Generation*). Le système repose sur trois étapes principales telles que l’extraction, l’indexation et la génération augmentée.

a. Extraction du contenu avec BeautifulSoup [34]

Lorsque l’utilisateur fournit un lien vers une page web, le backend utilise la bibliothèque **BeautifulSoup** (Python) pour analyser le code HTML et en extraire le contenu textuel pertinent. Seules les balises structurantes comme `<p>`, `<h1>`, `<h2>` sont conservées, tandis que les éléments décoratifs, interactifs ou publicitaires sont supprimés. Pour les fichiers PDF ou `.txt`, un autre extracteur est utilisé pour récupérer le texte brut.

b. Découpage et vectorisation (embeddings) [35]

Le texte brut est ensuite découpé en unités de taille fixe, appelées *chunks*. Chaque chunk est ensuite transformé en vecteur numérique à l’aide d’un modèle d’**embeddings** sémantiques, ici `text-embedding-ada-002` fourni par l’API OpenAI.

c. Indexation dans la base FAISS [36]

Les vecteurs générés sont ensuite stockés dans une base vectorielle construite avec **FAISS** (*Facebook AI Similarity Search*). Cet outil permet d’effectuer des recherches rapides de similarité entre vecteurs. Lorsqu’un utilisateur pose une question, celle-ci est également convertie en vecteur d’embedding, puis comparée aux vecteurs existants. Les chunks les plus proches sémantiquement sont ainsi identifiés.

d. Génération augmentée avec GPT-4

Les extraits de texte les plus adaptés retrouvés par FAISS sont rassemblés et ajoutés automatiquement au prompt envoyé à GPT-4. Cela permet de guider le modèle avec du contexte spécifique, issu des documents de l’utilisateur, et ainsi d’obtenir une réponse contextualisée, précise et fidèle aux sources.

Intégration dans le projet

— **Frontend** : L’utilisateur peut uploader un fichier (`.pdf`, `.txt`) ou soumettre une URL depuis l’interface React. Ces données sont envoyées au backend via `fetch()` et `FormData`.

- **Backend** : Le fichier ou l'URL est traité pour extraire le texte. BeautifulSoup est utilisé pour le web scraping, et pdfreader, BytesIO, Tiktoken pour les documents. Le texte est ensuite découpé, vectorisé avec l'API d'OpenAI, puis indexé dans FAISS.
- **Recherche et réponse** : Lorsqu'une question est posée par l'utilisateur, une requête RAG est lancée. Les meilleurs chunks sont extraits depuis l'index FAISS, puis envoyés dans le prompt de GPT-4. La réponse générée est retournée au frontend.
- **Sortie** : La réponse peut être affichée à l'écran (chat textuel) ou transformée en voix ou en vidéo animée, selon les paramètres définis.




FIGURE 3 – Architecture du RAG

4. Image et animation du visage

Pour obtenir une vidéo satisfaisante avec SadTalker, il est nécessaire de fournir une image de haute qualité, avec un visage bien centré et éclairé. Or, la photo d'origine de Piaget présentait une faible résolution et des teintes dégradées. Nous avons donc utilisé l'outil **HitPaw** [37]

pour améliorer la netteté, la luminosité et la colorisation de l'image. Cette version restaurée a ensuite été utilisée comme base pour l'animation.

Utilisation combinée de SadTalker et MuseTalk via l'API Fal

Dans notre application, l'animation d'une photo en vidéo est réalisée grâce à une API externe proposée par la plateforme *fal.ai*. Cette API permet de créer automatiquement une vidéo où le visage sur l'image semble parler, en se synchronisant avec un fichier audio généré par l'IA.

Même si notre code communique directement avec le modèle **MuseTalk**, celui-ci fonctionne en réalité avec un autre modèle appelé **SadTalker**, intégré dans la même API.

Concrètement, voici comment cela fonctionne :

SadTalker anime d'abord l'image en générant les mouvements du visage et de la tête à partir de la voix.

Ensuite, MuseTalk améliore la synchronisation des lèvres pour qu'elles correspondent plus précisément aux mots prononcés.

L'API de Fal.ai combine ces deux étapes automatiquement. Cela nous évite de gérer les modèles séparément et rend le développement beaucoup plus simple, tout en produisant un résultat réaliste et fluide à l'écran.

Il est important de noter que SadTalker applique un zoom automatique sur le visage afin de cadrer le personnage dans un format standard de type gros plan. Ce traitement explique pourquoi la vidéo produite reste toujours en *close shot* sur le visage.

L'utilisateur peut soit téléverser une image existante (photo du scientifique), soit générer un avatar à partir d'un prompt textuel via DALL-E. Cette image est utilisée à la fois pour l'affichage dans l'interface et pour l'animation vidéo. Si aucune image n'est fournie, le chat se limite à la voix.

5. Génération vidéo avec Ray2Flash (Fal.ai) [38]

Pour enrichir l'animation générée par SadTalker, nous avons intégré le modèle **Ray2Flash** de **Fal.ai** dans notre pipeline. Ray2Flash est un modèle de génération vidéo à grande échelle capable de créer des visuels réalistes avec un mouvement naturel et cohérent.

Fonctionnement du modèle Ray2Flash prend en entrée une image statique (par exemple, le visage de Jean Piaget) et un fichier audio (la voix synthétique générée), puis produit une séquence vidéo animée. Le modèle utilise des techniques de diffusion guidée par l'audio pour générer des mouvements réalistes du visage et du corps, synchronisés avec l'expressivité vocale. Contrairement à SadTalker, qui se concentre principalement sur la synchronisation labiale, Ray2Flash ajoute des micro-mouvements du corps, des épaules et de la tête, ainsi que des effets de caméra (comme des zooms ou des inclinaisons) pour une animation plus naturelle et immersive.

Intégration dans notre système Dans notre architecture, une fois que SadTalker a généré l'animation labiale, les images résultantes sont transmises à Ray2Flash. Cette dernière applique des animations supplémentaires pour produire une vidéo finale plus dynamique. Le backend encode ensuite la séquence en format .mp4 et la renvoie au frontend, où elle est affichée dans l'interface utilisateur.





FIGURE 4 – Diagramme de séquence

4.5 Prototype de l'application

Afin de valider l'implémentation fonctionnelle du système, une interface utilisateur a été développée. Les figures suivantes présentent les principales interfaces, illustrant les fonctionnalités clés de l'application.


Interprétation graphique :



The image shows a web-based interface for an application named 'Mentora'. At the top left is the 'Mentora' logo, which consists of a blue speech bubble icon and the word 'Mentora'. To the right of the logo is the heading 'Welcome to Mentora' in a large, bold, black font. Below the heading are two input sections. The first section is labeled 'Your Name:' and contains a text input field with the value 'Elham'. The second section is labeled 'Persona (Who do you want to chat with?):' and contains a text input field with the value 'Jean Piaget'. The interface is clean and modern, with a light gray background and rounded rectangular input fields.

FIGURE 5 – Interface d'accueil : saisie du nom

Interface d'accueil – Choix de la personne : l'utilisateur saisit le nom du scientifique avec lequel il souhaite discuter. Ce nom est ensuite transmis au modèle de langage (LLM), qui adapte ses réponses pour incarner ce personnage, en tenant compte de son style, de sa pensée et de son domaine d'expertise.



Clone a Voice

Upload Voice Sample:

Choose File examplevoice3min - isolated.mp3

Voice Name:


Jean piaget Voice

Clone Voice

Voice cloned successfully!

FIGURE 6 – Interface d’accueil : clonage de la voix

Clonage vocal : possibilité d’ajouter un extrait vocal pour cloner la voix de la personne sélectionnée, afin d’obtenir une synthèse vocale fidèle.



Bot Image (Optional)

Upload a photo:


Choose File finalPhoto.jpg

Do you need an avatar or edit your photo?

Edit or Make Avatar

FIGURE 7 – Interface d’accueil : ajouter une photo ou générer un avatar

Ajout ou génération d'un avatar : l'utilisateur peut importer une photo existante pour l'utiliser directement dans la génération de la vidéo animée. Alternativement, il peut cliquer sur le bouton "Edit" afin de transformer cette photo ou bien créer un avatar entièrement nouveau à partir d'un prompt textuel.



The image shows a web interface titled "Knowledge Source". Under the heading "Upload Document (PDF/DOCX/TXT):", there is a "Choose File" button followed by the text "stades_piaget.pdf". Below this is a green "Upload Document" button. Further down, under the heading "Or enter website URL:", there is a text input field containing "https://example.com". At the bottom is a grey "Fetch Website" button.

FIGURE 8 – Interface d'accueil : ajouter un document ou un lien web

Ajout de document ou lien web : l'utilisateur peut enrichir la base de connaissances de l'agent conversationnel en ajoutant des documents (PDF, textes) ou des URL, utilisés dans le système RAG. Ces contenus aident le LLM à produire des réponses plus précises et documentées.




FIGURE 9 – Interface de chat vocal : réponse audio avec voix clonée

Interface de chat vocal – Réponse en voix clonée : l'agent répond à l'utilisateur par la voix clonée, avec affichage du texte et selon les options choisies, animation vidéo synchronisée avec la voix.




FIGURE 10 – Réponse générée par le LLM, restituée en voix clonée

Réponse générée par le LLM, restituée en voix clonée : une fois la question posée par l'utilisateur, le modèle de langage (LLM) génère une réponse adaptée au personnage sélectionné. Cette réponse est ensuite convertie en voix synthétique grâce au clonage vocal personnalisé, pour offrir une interaction plus immersive.

The image shows a user interface for configuring a voice chat. It is divided into three main sections, each with a light gray header and a white content area.

- Language:** A dropdown menu with "English" selected and a downward arrow on the right.
- Chat Type:** A dropdown menu with "Educational" selected and a downward arrow on the right. Below it is a text input field containing "Custom chat type...". At the bottom of this section is a blue button labeled "Use Custom Type".
- Modify AI Prompt:** A text input field containing the placeholder text "Enter a detailed custom prompt...". At the bottom of this section is a blue button labeled "Insert Custom Prompt".

FIGURE 11 – Interface de chat vocal, le choix de la langue et le type de chat et la modification de l'IA

Sélection des paramètres d'interaction utilisateur-IA : l'utilisateur peut configurer l'expérience conversationnelle selon ses préférences tels que la langue de l'échange, le type de chat, et même modifier le comportement de l'IA via un prompt personnalisé.




FIGURE 12 – Interface de chat : réponse sous forme de vidéo animée synchronisée

Réponse animée en vidéo : si une photo a été fournie, la réponse est générée sous forme de vidéo animée, avec synchronisation labiale et mouvements du visage (et du haut du corps), grâce à des outils comme SadTalker ou Ray2Flash, pour renforcer l'effet de présence du personnage.




FIGURE 13 – Interface de génération d'avatar à partir d'un prompt

Génération d'avatar text-to-image : en alternative à l'upload d'image, l'utilisateur peut simplement saisir une description textuelle (prompt) pour générer un avatar personnalisé avec l'aide de DALL-E, utilisable ensuite dans l'interface de chat comme image animée.

4.6 Tests, évaluations et retours

Tout au long du développement, des tests techniques et fonctionnels ont été réalisés pour valider le bon fonctionnement de chaque module, également pour évaluer l'expérience utilisateur.

Tests techniques

- **Clonage vocal** : Nous avons testé plusieurs outils de clonage vocal, et les résultats ont montré que ElevenLabs offrait la meilleure qualité de synthèse, notamment en termes de clarté, d'intonation et de fluidité. Cependant, même avec cet outil, certaines limites subsistent.
- **Synchronisation labiale** : l'outil comme SadTalker a été testé sur la photo de Jean Piaget. Les résultats étaient acceptables en vue frontale, avec une synchronisation des lèvres généralement correcte. Cependant, la qualité de l'image d'entrée s'est révélée déterminante, les outils testés nécessitent une photo nette, bien éclairée et à haute résolution pour générer des animations réalistes. Or, dans notre cas, les images historiques disponibles étaient limitées en qualité mal cadrées. Malgré des tentatives d'amélioration via des outils comme HitPaw Photo Enhancer, n'atteint pas un bon niveau de qualité.
- **NLP et cohérence des réponses** : Le système NLP utilisé (basé sur GPT-4) a été capable de générer des réponses globalement cohérentes et en lien avec les questions posées. Lorsqu'on lui posait des questions inspirées des écrits de Jean Piaget, les réponses obtenues étaient pertinentes et proches de ses idées. L'ajout du système RAG, qui permet d'appuyer les réponses sur des documents spécifiques, a encore renforcé cette cohérence en rendant les réponses plus précises et documentées.
- **Chaîne de traitement voix-texte-vidéo** : Le pipeline complet a été testé dans des scénarios de conversation vocale, depuis la capture de la voix de l'utilisateur jusqu'à la restitution d'une réponse animée. Chaque étape, la reconnaissance vocale, la génération de texte via le LLM, la synthèse vocale clonée, puis l'animation vidéo a pu être validée individuellement et enchaînée de manière cohérente.

Retours d'expérimentation

Le prototype a été testé auprès de notre entourage. Voici les principaux retours qualitatifs observés :

- L'idée d'échanger avec un scientifique a été perçue comme originale et pertinente pour des usages éducatifs ou culturels.
- L'animation du visage a été jugée convaincante, bien que dépendante de la qualité de la photo fournie. Certains testeurs ont noté un manque de fluidité dans les mouvements.
- Un effet d'écho a été constaté lors des réponses du bot, dû à la lecture simultanée de l'audio synthétique et de la vidéo animée. Ce problème était accentué par le fait que le micro restait actif pendant la réponse. Pour y remédier, nous avons ajouté une désactivation temporaire du micro pendant la lecture, ainsi qu'un bouton Pause permettant d'interrompre la conversation si nécessaire.

- La voix clonée a été globalement bien reçue, même si les intonations, pauses et accents restent parfois artificiels, en particulier pour les longues réponses.
- Les réponses issues du système RAG (avec documents ou liens web) ont été jugées plus précises, mais prennent plus de temps à générer que les réponses sans contexte. Cela a parfois généré de la frustration chez les utilisateurs qui attendaient un échange rapide.
- La génération de vidéo (SadTalker + Ray2Flash) ajoute un délai important entre la question et la réponse, surtout pour les longues phrases. Le processus complet la transformation d'un texte écrit en une vidéo animée est long, et dépend en partie des ressources matérielles disponibles. Cela limite la fluidité d'une conversation vocale en temps réel.
- L'interface a été considérée comme claire dans l'ensemble, mais quelques ajustements restent nécessaires pour la rendre plus intuitive et adaptée aux écrans mobiles.

Limites constatées

Après des phases d'usage et de tests, nous avons identifié plusieurs limites qui affectent encore l'expérience utilisateur ou la performance globale du système :

- **Qualité d'image insuffisante** : la plupart des photos historiques disponibles sont floues, mal cadrées ou bruitées. Cela affecte négativement la qualité des animations SadTalker, même après tentative d'amélioration HitPaw. L'absence de vidéos empêche l'entraînement de modèles expressifs.
- **Latence dans les réponses** : Bien que le système soit globalement fonctionnel, la génération des vidéos animées induit une certaine latence qui effect la fluidité d'un échange en temps réel. Le processus complet, de la question à la génération vidéo via GPT et la synthèse vocale, induit une latence non négligeable. Particulièrement avec les outils comme SadTalker, Ray2Flash, qui nécessitent une puissance de calcul élevée. Cela compromet l'objectif d'une conversation fluide en temps réel.
- **RAG : compromis entre richesse contextuelle et vitesse** : les réponses enrichies par RAG sont plus fiables, mais nécessitent un temps de traitement plus long, notamment pour le chargement, l'analyse et l'intégration du document. Cela peut frustrer l'utilisateur en attente d'une réponse rapide.
- **Interface à améliorer** : Bien que fonctionnelle, l'interface présente encore des limites sur les appareils mobiles, notamment en termes d'ergonomie, de taille des boutons et de navigation, cela pourrait être améliorée visuellement pour offrir une expérience plus fluide.
- **Coûts et limitations des outils** : plusieurs services utilisés sont payants ou fortement restreints en version gratuite (Ex. : ElevenLabs, Ray2Flash, OpenAI).
- **Manque d'expertise thématique** : en l'absence de connaissances approfondies sur les écrits complexes de Jean Piaget, les tests de cohérence NLP sont restés sur des questions simples et générales. Une expertise scientifique plus poussée serait nécessaire pour une validation rigoureuse.

5 Discussion et perspectives

5.1 Réponses aux questions de recherche

Cette section vise à évaluer dans quelle mesure les choix techniques réalisés tout au long du projet ont permis de répondre aux questions de recherche initialement posées. Elle synthétise les enseignements tirés de l’expérimentation, en s’appuyant sur les résultats concrets du développement et des tests réalisés. Les axes abordés couvrent à la fois les aspects techniques, visuels, interactifs et éducatifs du prototype.

Recréation de la personnalité scientifique : Le projet a permis de démontrer qu’il est aujourd’hui possible de simuler la personnalité d’un scientifique historique en combinant des technologies de clonage vocal, de génération de texte et d’animation faciale. À partir d’archives limitées, nous avons pu reconstituer une voix proche de celle de Jean Piaget, générer des réponses inspirées de ses écrits, et animer une photo pour lui redonner une forme de présence. Le système a ainsi pu produire des réponses claires et cohérentes, à la fois sur le fond (fidèles à sa pensée) et sur la forme (style oral naturel). Cette approche offre une expérience de dialogue convaincante avec une figure historique incarnée.

Animation faciale à partir d’une photo : L’un des principaux défis techniques consistait à animer le visage de Piaget à partir d’une seule image, sans utiliser de modèle 3D complexe. Grâce à l’outil SadTalker pour les mouvements de tête et d’expression, et à MuseTalk pour affiner la synchronisation labiale, nous avons pu générer des vidéos réalistes, où la voix synthétique semble correctement articulée. Bien que la qualité du résultat dépende fortement de la photo choisie (résolution, éclairage, cadrage), cette approche 2D s’est révélée efficace et bien plus accessible techniquement que la modélisation 3D.

Intégration d’une interface interactive multimodale : L’application développée regroupe plusieurs technologies avancées compris traitement du langage (GPT), synthèse vocale (TTS), reconnaissance vocale, animation faciale, et génération d’avatars dans une interface unique, fluide et responsive. L’architecture choisie, basée sur React côté client et FastAPI côté serveur, facilite l’organisation des modules et leur interaction. L’utilisateur peut personnaliser l’agent (image, voix, style de réponse), choisir son mode d’échange (oral ou écrit), et recevoir une réponse sous forme textuelle, vocale ou vidéo animée. Ce système intégré montre qu’il est possible de réunir plusieurs outils puissants dans une seule application cohérente, même avec des ressources limitées.

Fiabilité et cohérence des réponses : Pour garantir que les réponses générées soient proches de la pensée de Jean Piaget, nous avons mis en place un système de RAG. Celui-ci permet au modèle GPT de s’appuyer sur des documents pertinents (ouvrages, articles, extraits biographiques) pour formuler des réponses mieux ancrées dans les sources. Cette méthode a permis d’améliorer considérablement la précision et la pertinence des réponses, notamment sur des questions portant sur la psychologie de l’enfant ou l’épistémologie.

Fidélité visuelle de l’avatar : Représenter visuellement un personnage historique à partir d’une photo unique constitue un défi, surtout lorsque les images disponibles sont anciennes ou de faible qualité. Dans notre projet, certaines images de Piaget ont nécessité un travail de sélection

et d'amélioration pour obtenir un résultat satisfaisant. Malgré ces contraintes, nous avons réussi à conserver certains traits caractéristiques du personnage (lunettes, morphologie du visage, expression générale), ce qui contribue à l'identification visuelle et à la continuité de l'expérience.

Immersion sans recours à la 3D : Enfin, le projet a montré qu'une immersion convaincante peut être obtenue sans passer par une modélisation 3D lourde. L'animation faciale en 2D, combinée à une voix synthétique crédible et à un système NLP performant, permet une expérience fluide, naturelle et engageante. Ce choix technique rend l'application plus légère, plus rapide à déployer, et accessible même avec des ressources limitées. Cela ouvre la voie à d'autres usages dans le domaine éducatif.

5.2 Limites de la solution actuelle

Malgré les résultats encourageants, plusieurs limitations ont été identifiées lors des tests :

- **Expressivité vocale limitée :** Le clonage vocal utilisé dans ce projet s'appuie sur un service commercial, ce qui entraîne certaines restrictions dans sa version gratuite.

De plus, l'outil n'a pas entièrement réussi à reproduire avec précision les caractéristiques naturelles de la voix, telles que le rythme, les pauses, les respirations ou les intonations propres au français. Cette absence de prosodie réaliste rend les réponses parfois monotones ou mécaniques, ce qui nuit à l'authenticité de l'échange, surtout lors de réponses longues ou complexes.

Cependant, la qualité des enregistrements originaux de Jean Piaget ne s'est pas révélée problématique, les extraits disponibles étaient suffisamment clairs pour être exploités.

- **Temps de génération élevé :** La génération complète (texte, audio, vidéo) est relativement lente. Cela empêche toute interaction en temps réel, ce qui limite les possibilités d'un échange oral fluide et naturel.
- **Animation faciale imparfaite :** L'animation reste centrée sur un plan fixe du visage (close shot), sans inclusion du corps ou d'expressions complexes. De plus, certains mouvements du visage manquent de fluidité, et les transitions peuvent sembler artificielles, réduisant la crédibilité de l'avatar animé.
- **Interface utilisateur perfectible :** L'interface nécessite encore des ajustements, notamment en ce qui concerne la compatibilité mobile, l'accessibilité (voix, navigation clavier) et la fluidité générale de l'expérience utilisateur.
- **Absence de validation experte :** Bien que les réponses générées par le LLM soient généralement cohérentes et informatives, leur fiabilité académique ne peut être pleinement garantie sans validation humaine. En l'absence d'un expert du domaine pour évaluer les contenus extraits par le système RAG, certaines réponses peuvent rester approximatives, en particulier lorsque les sources sont mal structurées ou peu pertinentes. L'intervention d'un spécialiste s'avère donc essentielle pour assurer la pertinence, l'exactitude et la fidélité des informations fournies par le modèle.
- **Absence de base de données centralisée :** Les réponses générées et les vidéos produites ne sont actuellement pas sauvegardées. Chaque nouvelle requête entraîne une génération

complète, même si une réponse identique a déjà été produite auparavant. Cela augmente les délais de réponse, consomme davantage de ressources, et nuit à l'efficacité globale du système.

5.3 Perspectives d'amélioration

Plusieurs pistes d'amélioration ont été identifiées afin de renforcer les performances, la fluidité et la fiabilité scientifique de l'application. Ces pistes s'appuient à la fois sur les limites constatées durant le développement, et sur les nouvelles technologies ou outils récents offrant de nouvelles possibilités.

- **Clonage local** : Pour une application éducative grand public ou un projet open source, l'utilisation d'une solution locale comme Coqui TTS peut représenter une alternative intéressante. À condition de disposer du matériel nécessaire (notamment un GPU), d'un corpus vocal de qualité et d'un pipeline d'entraînement bien configuré, il est possible de mettre en place un système de clonage vocal libre, reproductible et durable, sans dépendance à une API externe.
- **Réduction du temps de réponse** : Actuellement, le temps de génération audio et vidéo empêche une interaction véritablement en temps réel. Une priorité pour les prochaines évolutions du projet consistera à accélérer le temps de génération des réponses multimodales. Cela pourrait passer par de l'optimisation des appels API, du pré-chargement des modules critiques, ou du cache de réponses déjà traitées.
- **Stockage des échanges pour éviter la redondance** : La mise en place d'une base de données permettrait de mémoriser les questions posées, les réponses générées, ainsi que les vidéos correspondantes. Cela aurait un double avantage compris éviter de régénérer inutilement des contenus identiques, et assurer une continuité dans le dialogue. Une telle mémoire pourrait aussi renforcer le réalisme de l'échange, en donnant au personnage une forme de persistance.
- **Amélioration de la qualité des réponses RAG** : Dans notre projet, le système RAG repose sur un principe simple, lorsque l'utilisateur pose une question, le système commence par rechercher, dans une base de documents, les passages les plus pertinents. Cette recherche est faite à l'aide de "vecteurs d'embeddings", c'est-à-dire des représentations numériques du sens des textes. On compare alors la question posée avec les documents disponibles pour retrouver ceux qui ont un sens proche.

Cependant, cette méthode peut parfois ramener des documents peu fiables, redondants ou hors sujet. Pour améliorer la qualité des réponses, plusieurs pistes sont envisageables :

Filtrage des sources : mettre en place un mécanisme qui évalue la qualité des documents récupérés (par exemple, favoriser des publications scientifiques plutôt que des blogs) avant de les transmettre au modèle.

Pondération selon la fiabilité : attribuer un "poids" à chaque document selon sa provenance ou sa rigueur (ex. un article de Wikipédia noté moins qu'un article académique), afin que le modèle GPT tienne davantage compte des sources les plus fiables dans sa réponse.

Reformulation automatique du contexte : une fois les documents sélectionnés, un prétraitement pourrait résumer ou restructurer leur contenu pour mieux le transmettre au modèle de génération. Cela évite les doublons ou les passages inutiles et clarifie le contexte.

En combinant ces techniques, on obtiendrait un système RAG plus intelligent, capable non seulement de retrouver des documents pertinents, mais aussi de fournir à l'IA un contexte plus clair, précis et fiable et le résultat des réponses plus justes, mieux argumentées et plus adaptées à la question posée.

- **Validation experte ou LLM personnalisé :** Afin d'assurer une plus grande fidélité aux idées de Jean Piaget, un LLM personnalisé pourrait être entraîné uniquement sur ses œuvres, articles, conférences, et documents historiques. Cette spécialisation permettrait de limiter les erreurs d'interprétation et de garantir une meilleure cohérence intellectuelle. En parallèle, un outil de vérification de cohérence avec les sources pourrait compléter ce dispositif.
- **Incarnation 3D réaliste du personnage :** Une piste prometteuse serait de créer un modèle 3D fidèle de Jean Piaget, basé sur les rares photographies existantes, pour permettre des animations plus complètes, incluant les mouvements du corps, les postures et les expressions complexes. L'usage d'outils comme MetaHuman ou Ready Player Me pourrait offrir une base, mais leur adaptation nécessiterait un important travail de modélisation, ainsi qu'un matériel adapté à la projection ou à l'intégration 3D. Cette étape constituerait un pont vers un hologramme interactif, mais à plus long terme.
- **Vers une incarnation holographique complète :** Une évolution envisageable du projet consisterait à dépasser l'animation faciale actuelle pour développer un modèle 3D complet du personnage (incluant le corps, la tête et les gestes), dans l'objectif d'une projection holographique plus réaliste. Cette démarche permettrait de proposer des expériences immersives dans des événements éducatifs ou culturels.

Parmi les technologies accessibles dans ce domaine, le dispositif dit "Pepper's Ghost" constitue une solution particulièrement intéressante. Il s'agit d'un système de projection qui donne l'illusion d'un hologramme en grandeur nature, grâce à une vidéo affichée sur un écran incliné et réfléchi via une vitre semi-transparente. Cette technique a déjà été utilisée avec succès pour recréer des personnages historiques ou des artistes sur scène.

Cependant, pour que cette approche soit applicable à notre projet, plusieurs conditions techniques doivent être réunies. Notamment, il serait nécessaire de disposer d'une vidéo en haute qualité du personnage animé (visage et corps entier), ce qui suppose à son tour une photo de départ de très bonne qualité ainsi qu'un modèle 3D animé suffisamment fidèle. À ce jour, la rareté et la faible résolution des images de Jean Piaget limitent cette possibilité, mais une amélioration des ressources visuelles (via restauration ou génération d'image) pourrait ouvrir la voie à ce type de rendu holographique.

Cette perspective, bien qu'ambitieuse, propose une extension concrète et réaliste de notre projet dans le futur, en combinant les avancées logicielles (animation 3D, synthèse vocale) avec des dispositifs physiques de mise en scène (Pepper's Ghost, AR/VR), pour enrichir l'incarnation numérique et lui donner une présence scénographique tangible.

6 Conclusion

Au fil de ce travail, nous avons montré qu’il est désormais possible, à partir d’une seule photo, de quelques minutes d’archives audio et des modèles d’intelligence artificielle disponibles aujourd’hui, de redonner la voix et la présence à une figure scientifique. La combinaison d’un modèle de langage de dernière génération, d’un clonage vocal expressif et d’une animation faciale synchronisée crée une nouvelle façon de transmettre le savoir, plus vivante et interactive, où l’utilisateur ne se contente plus de lire, mais peut réellement dialoguer.

Notre prototype présente encore certaines limites :

Latence : Le passage successif du traitement GPT à la synthèse vocale, puis à l’animation, introduit un délai perceptible.

Expressivité : la synchronisation labiale et les gestes restent perfectibles, surtout dans les échanges rapides ou émotionnels.

Validation scientifique : les réponses générées nécessitent encore une relecture experte pour garantir l’exactitude historique et conceptuelle.

Malgré ces limites, l’expérience réalisée démontre un potentiel concret pour transformer des fonds d’archives en rencontres vivantes, accessibles depuis un simple navigateur. Cette approche ouvre des perspectives éducatives et interactives inédites :

- Musées et expositions : Lors d’une séance de médiation, les visiteurs peuvent interroger « en personne » un scientifique disparu. L’avatar répond, commente les objets présentés et replace les découvertes dans leur contexte.
- Salle de classe : Les élèves interrogent un scientifique sur des théories actuelles (neurosciences, IA, etc.), l’IA confronte alors les travaux originaux de ce expert à nos connaissances contemporaines, stimulant ainsi la pensée critique.
- Événements de vulgarisation : Conférences interactives, stands grand public ou plateformes en ligne peuvent utiliser l’application pour créer des dialogues immersifs, dynamisant l’apprentissage et la curiosité.

À terme, un déploiement local des modèles, l’intégration d’avatars 3D complets et la constitution d’un corpus validé par des spécialistes permettront d’améliorer la fluidité, la rigueur scientifique et l’immersivité. En l’état, notre projet illustre déjà une nouvelle façon d’apprendre et de dialoguer avec le passé, une passerelle entre patrimoine et technologies émergentes, porteuse d’expériences pédagogiques riches et engageantes.

Note sur la rédaction

Certaines parties de ce manuscrit ont été reformulées ou corrigées à l'aide d'un modèle de langage génératif, afin de garantir une présentation professionnelle et conforme aux standards académiques.

Références

- [1] Inc. Luka. Replika - your ai friend, 2024. <https://replika.com>.
- [2] Soul Machines. Digital people powered by ai, 2024. <https://www.soulmachines.com>.
- [3] Epic Games. Metahuman creator, 2024. <https://www.unrealengine.com/en-US/metahuman>.
- [4] Uneeq. Digital einstein – an ai-powered digital human by uneeq. <https://www.digitalhumans.com/blog/uneeq-uses-experiential-ai-to-bring-albert-einstein-back-to-life-as-latest-digital-companion>, 2021. Consulté en juin 2025.
- [5] D-ID. Ai generated video creation platform, 2023. <https://www.d-id.com>.
- [6] MyHeritage. Deep nostalgia, 2024. <https://www.myheritage.com/deep-nostalgia>.
- [7] ElevenLabs. Elevenlabs - ai voice cloning for creators, 2024. <https://www.elevenlabs.io>.
- [8] Resemble AI. Real-time voice cloning for developers, 2024. <https://www.resemble.ai/>.
- [9] iSpeech. Text to speech and voice cloning, 2024. <https://www.ispeech.org>.
- [10] ActuaIA, 2021. <https://www.actuia.com/actualite/des-chercheurs-du-mit-ont-utilise-le-deep-learning-pour-generer-des-hologrammes-3d-instantanement/>.
- [11] Utilisateur Debian-fr. Open source hologram, 2023. <https://www.debian-fr.org/t/open-source-hologram/87488>.
- [12] PlayHT. Playht - ai voice generator & realistic text to speech, 2024. <https://www.play.ht>.
- [13] Real-Time Voice Cloning. Real-time voice cloning - github project, 2020. <https://github.com/CoirentinJ/Real-Time-Voice-Cloning>.
- [14] Coqui. Coqui tts - open source text-to-speech library, 2024. <https://github.com/coqui-ai/TTS>.
- [15] Jonathan Shen, Ruoming Pang, Ron J. Weiss, Mike Schuster, Navdeep Jaitly, Zongheng Yang, Zhifeng Chen, Yu Zhang, Yuxuan Wang, R.J. Skerry-Ryan, Rif A. Saurous, Yannis Agiomyrgianakis, and Yonghui Wu. Natural tts synthesis by conditioning wavenet on mel spectrogram predictions. *arXiv preprint arXiv :1712.05884*, 2017. <https://arxiv.org/abs/1712.05884>.
- [16] Yi Ren, Chenxu Hu, Xu Tan, Tao Qin, Sheng Zhao, Zhou Zhao, and Tie-Yan Liu. FastSpeech 2 : Fast and high-quality end-to-end text to speech. *arXiv preprint arXiv :2006.04558*, 2020. <https://arxiv.org/abs/2006.04558>.
- [17] LiHu, XinGao, PengZhang, KeSun, BangZhang, and LiefengBo. Animate anyone : Consistent and controllable image-to-video synthesis for character animation. *arXiv preprint arXiv :2311.17117*, 2023. Disponible en ligne via GitHub Pages (<https://humanaigc.github.io/animate-anyone/>).
- [18] Prajwal K R, Rudrabha Mukhopadhyay, Jerin Philip, Abhishek Jha, Vinay Namboodiri, and C V Jawahar. Wav2lip : Accurately lip-syncing videos in the wild. In *Proceedings of the 28th ACM International Conference on Multimedia (MM '20)*, page 3534–3542, 2020. <https://arxiv.org/abs/2008.10010>.

- [19] D-ID. D-id : Create ai-generated talking avatars from photos, 2023. <https://www.d-id.com/>.
- [20] Vidnoz. Vidnoz ai - text to video with talking photo, 2024. <https://www.vidnoz.com>.
- [21] SadTalker. Sadtalker - realistic face animation from single image, 2023. <https://github.com/OpenTalker/SadTalker>.
- [22] Fal.AI. Musetalk : Ai lip sync from image to video, 2024. <https://fal.ai>.
- [23] HeyGen. Heygen - ai video generator with talking avatars, 2023. <https://www.heygen.com>.
- [24] Voxcraft : Free 3d ai generator. <https://voxcraft.ai>.
- [25] Polycam : 3d scanner and editor. <https://poly.cam>.
- [26] Luma Labs. Luma ai - capture and recreate the world in 3d, 2023. <https://lumalabs.ai>.
- [27] DeepMotion Inc. Deepmotion - ai motion capture & real-time animation, 2023. <https://www.deepmotion.com>.
- [28] Wolf3D. Ready player me - cross-game avatar platform for the metaverse. <https://readyplayer.me>.
- [29] Fal.AI. Ray2flash : Luma dream machine for video generation, 2024. <https://fal.ai>.
- [30] Vincent Mühler. face-api.js, 2018. <https://github.com/justadudewhohacks/face-api.js>.
- [31] Deepbrain ai. <https://www.deepbrain.io>.
- [32] Epic Games. Metahuman creator, 2023.
- [33] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Igor Kulikov, Kyunghyun Cho, Angela Fan, Edouard Grave, Veselin Stoyanov, and Yonatan Bisk. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [34] Leonard Richardson. BeautifulSoup : Html and xml parser, 2023. <https://www.crummy.com/software/BeautifulSoup/>.
- [35] OpenAI. text-embedding-ada-002 : Openai embedding model, 2022. <https://platform.openai.com/docs/guides/embeddings>.
- [36] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Faiss : Facebook ai similarity search. <https://github.com/facebookresearch/faiss>, 2017. Outil open-source pour la recherche de similarité vectorielle.
- [37] Hitpaw. <https://www.hitpaw.net/>.
- [38] Fal.ai. Luma ray 2 flash (image to video), 2024. <https://fal.ai/models/fal-ai/luma-dream-machine/ray-2-flash/image-to-video>.